

# سیستم هوشمند تشخیص حواس پرتی راننده

یادگیری ماشین



نام دانشجو: حامد بهروزی مقدم - امیرحسین شقاقی

شماره دانشجویی: ۴۰۱۱۹۸۴۳ - ۴۰۲۱۵۶۳۳

استاد درس: دکتر نیکوفرد

نیمسال: ۱۴۰۵-۱۴۰۴

کد پروژه: مشاهده در Kaggle

مجموعه داده: Dataset Farm State

گیت هاب پروژه: Hamed-۲۰۰۴

## فهرست مطالب

|    |       |                                                            |
|----|-------|------------------------------------------------------------|
| ۴  | ۱     | مقدمه و کلیات پژوهش                                        |
| ۴  | ۱.۱   | مقدمه و بیان مسئله                                         |
| ۴  | ۲.۱   | اهمیت و ضرورت موضوع                                        |
| ۵  | ۳.۱   | چالش‌های فنی بینایی ماشین در داخل کابین خودرو              |
| ۵  | ۴.۱   | اهداف پژوهش و روش‌شناسی پیشنهادی                           |
| ۶  | ۲     | مرور ادبیات و کارهای مرتبط                                 |
| ۶  | ۱.۲   | مقدمه                                                      |
| ۶  | ۲.۲   | روش‌های سنتی پردازش تصویر و یادگیری ماشین                  |
| ۶  | ۱.۲.۲ | محدودیت‌های روش‌های سنتی                                   |
| ۷  | ۳.۲   | سقوط روش‌های سنتی و ظهور یادگیری عمیق                      |
| ۷  | ۴.۲   | مرور پژوهش‌های برجسته بر روی مجموعه داده Farm State        |
| ۷  | ۱.۴.۲ | استفاده از معماری‌های پایه CNN و یادگیری انتقالی           |
| ۷  | ۲.۴.۲ | توسعه معماری‌های سبک و بهینه‌سازی برای سیستم‌های Embedded  |
| ۸  | ۳.۴.۲ | رویکردهای تلفیقی و ترنسفورمرهای بینایی                     |
| ۸  | ۵.۲   | مقایسه و جمع‌بندی ادبیات تحقیق                             |
| ۸  | ۶.۲   | نتیجه‌گیری و جایگاه پژوهش حاضر                             |
| ۹  | ۳     | مبانی نظری و فرمول‌بندی ریاضی                              |
| ۹  | ۱.۳   | مقدمه                                                      |
| ۹  | ۲.۳   | مبانی شبکه‌های عصبی پیچشی (CNN)                            |
| ۹  | ۱.۲.۳ | عملگر کانولوشن دوبعدی (2D_Convolution)                     |
| ۹  | ۲.۲.۳ | لایه‌های کاهش بعد (Pooling_Layers)                         |
| ۱۰ | ۳.۲.۳ | توابع فعال‌سازی (Activation_Functions)                     |
| ۱۰ | ۳.۳   | معماری ResNet۵۰ و اتصالات باقیمانده                        |
| ۱۰ | ۱.۳.۳ | مفهوم یادگیری باقیمانده (Residual_Learning)                |
| ۱۱ | ۲.۳.۳ | بلاک گلوگاه (BottleneckArchitecture)                       |
| ۱۱ | ۴.۳   | معماری MobileNetV۲ و بهینه‌سازی محاسباتی                   |
| ۱۱ | ۱.۴.۳ | کانولوشن تفکیک‌پذیر عمقی (Depthwise_Separable_Convolution) |
| ۱۲ | ۲.۴.۳ | بلاک باقیمانده معکوس (Inverted_Residual_Block)             |
| ۱۲ | ۵.۳   | تابع زیان و الگوریتم بهینه‌سازی                            |



|    |                                                                  |       |
|----|------------------------------------------------------------------|-------|
| ۱۲ | ..... تابع زیان انتروپی متقاطع (Categorical_Cross_Entropy_Loss)  | ۱.۵.۳ |
| ۱۳ | ..... بهینه‌ساز Adam_(Adaptive_Moment_Estimation)                | ۲.۵.۳ |
| ۱۳ | ..... جمع‌بندی فصل                                               | ۶.۳   |
| ۱۴ | ..... تحلیل مجموعه داده و پیش‌پردازش                             | ۴     |
| ۱۴ | ..... مقدمه                                                      | ۱.۴   |
| ۱۴ | ..... معرفی مجموعه داده Farm State                               | ۲.۴   |
| ۱۸ | ..... تحلیل آماری و ساختار داده‌ها                               | ۳.۴   |
| ۲۲ | ..... تکنیک‌های افزایش داده (Data_Augmentation)                  | ۴.۴   |
| ۲۲ | ..... تغییرات هندسی و رنگی                                       | ۱.۴.۴ |
| ۲۵ | ..... تغییر ابعاد و نرمال‌سازی تصاویر ورودی                      | ۵.۴   |
| ۲۵ | ..... تغییر مقیاس فضایی (Resizing)                               | ۱.۵.۴ |
| ۲۶ | ..... پیش‌پردازش و نرمال‌سازی اختصاصی مدل‌ها                     | ۲.۵.۴ |
| ۲۷ | ..... جمع‌بندی فصل                                               | ۶.۴   |
| ۲۸ | ..... معماری پیشنهادی و روش‌شناسی                                | ۵     |
| ۲۸ | ..... مقدمه                                                      | ۱.۵   |
| ۲۸ | ..... معماری شبکه و لایه‌های سفارشی (Custom_Classification_Head) | ۲.۵   |
| ۲۸ | ..... ساختار لایه‌های سفارشی                                     | ۱.۲.۵ |
| ۲۹ | ..... معماری شبکه پیشنهادی مبتنی بر MobileNetV۲                  | ۲.۲.۵ |
| ۳۰ | ..... معماری شبکه پیشنهادی مبتنی بر ResNet۵۰                     | ۳.۲.۵ |
| ۳۱ | ..... استراتژی آموزش دو فازی (Two-Phase_Training_Strategy)       | ۳.۵   |
| ۳۲ | ..... فاز اول: استخراج ویژگی (Feature_Extraction)                | ۱.۳.۵ |
| ۳۲ | ..... فاز دوم: تنظیم دقیق (Fine-Tuning)                          | ۲.۳.۵ |
| ۳۲ | ..... هایپرپارامترها و مکانیزم‌های کنترلی آموزش                  | ۴.۵   |
| ۳۲ | ..... تنظیمات هایپرپارامترها                                     | ۱.۴.۵ |
| ۳۳ | ..... کال‌بک‌ها و مکانیزم‌های کنترلی (Callbacks)                 | ۲.۴.۵ |
| ۳۳ | ..... جمع‌بندی فصل                                               | ۵.۵   |
| ۳۴ | ..... نتایج تجربی و ارزیابی عملکرد                               | ۶     |
| ۳۴ | ..... مقدمه                                                      | ۱.۶   |
| ۳۴ | ..... نتایج ارزیابی مدل ResNet۵۰                                 | ۲.۶   |
| ۳۶ | ..... تحلیل گام به گام آموزش و ارزیابی مدل ResNet۵۰              | ۱.۲.۶ |
| ۳۸ | ..... نتایج ارزیابی مدل MobileNetV۲                              | ۳.۶   |
| ۳۸ | ..... نتایج ارزیابی مدل MobileNetV۲                              | ۱.۳.۶ |
| ۴۱ | ..... ماتریس درهم‌ریختگی و تحلیل خطاها                           | ۴.۶   |
| ۴۱ | ..... تحلیل ماتریس درهم‌ریختگی مدل MobileNetV۲                   | ۱.۴.۶ |



|    |                                                                                 |       |
|----|---------------------------------------------------------------------------------|-------|
| ۴۲ | تحلیل منحنی‌های ROC و شاخص AUC مدل MobileNetV۲                                  | ۲.۴.۶ |
| ۴۳ | تحلیل ماتریس درهم‌ریختگی مدل ResNet۵۰                                           | ۳.۴.۶ |
| ۴۴ | تحلیل منحنی‌های ROC و شاخص AUC مدل ResNet۵۰                                     | ۴.۴.۶ |
| ۴۵ | مقایسه جامع عملکرد مدل‌ها                                                       | ۵.۶   |
| ۴۶ | مقایسه کیفی پیش‌بینی‌های ResNet۵۰ و MobileNetV۲ روی داده‌های آزمون              | ۱.۵.۶ |
| ۴۷ | مقایسه روند همگرایی و منحنی‌های دقت (Accuracy_Curves)                           | ۲.۵.۶ |
| ۴۸ | نمونه خروجی‌های کیفی و استنتاج روی داده‌های آزمون                               | ۶.۶   |
| ۴۹ | جمع‌بندی فصل                                                                    | ۷.۶   |
| ۵۰ | چالش‌های فنی، موانع اجرایی و راهکارهای مواجهه                                   | ۷     |
| ۵۰ | مقدمه                                                                           | ۱.۷   |
| ۵۰ | چالش اول: شباهت بالای بین‌کلاسی و همپوشانی رفتاری (High_Inter_class_Similarity) | ۲.۷   |
| ۵۰ | تحلیل ابعاد چالش                                                                | ۱.۲.۷ |
| ۵۰ | راهکار اتخاذشده                                                                 | ۲.۲.۷ |
| ۵۰ | چالش دوم: چالش بیش‌برازش (Overfitting) و عدم تعادل داده‌ها                      | ۳.۷   |
| ۵۱ | تحلیل ابعاد چالش                                                                | ۱.۳.۷ |
| ۵۱ | راهکار اتخاذشده                                                                 | ۲.۳.۷ |
| ۵۱ | چالش سوم: فرار گرادیان و تخریب وزن‌ها در فاز Fine-Tuning                        | ۴.۷   |
| ۵۱ | تحلیل ابعاد چالش                                                                | ۱.۴.۷ |
| ۵۱ | راهکار اتخاذشده                                                                 | ۲.۴.۷ |
| ۵۲ | چالش چهارم: شرایط نوری پیچیده، نور شدید مستقیم و سایه‌های کابین                 | ۵.۷   |
| ۵۲ | تحلیل ابعاد چالش                                                                | ۱.۵.۷ |
| ۵۲ | راهکار اتخاذشده                                                                 | ۲.۵.۷ |
| ۵۲ | جمع‌بندی فصل                                                                    | ۶.۷   |
| ۵۳ | نتیجه‌گیری، دستاوردها و پیشنهادات برای پژوهش‌های آتی                            | ۸     |
| ۵۳ | مقدمه                                                                           | ۱.۸   |
| ۵۳ | خلاصه پژوهش و دستاوردهای کلیدی                                                  | ۲.۸   |
| ۵۳ | خلاصه نتایج کمی                                                                 | ۱.۲.۸ |
| ۵۴ | بحث و موازنه دقت و کارایی محاسباتی (Trade_off_Analysis)                         | ۳.۸   |
| ۵۴ | پیشنهادات برای پژوهش‌های آتی                                                    | ۴.۸   |
| ۵۴ | سخن پایانی                                                                      | ۵.۸   |

## ۱ مقدمه و کلیات پژوهش

### ۱.۱ مقدمه و بیان مسئله

امروزه حوادث رانندگی و تصادفات جاده‌ای به عنوان یکی از اصلی‌ترین عوامل مرگ‌ومیر و معلولیت‌های جسمی در سراسر جهان شناخته می‌شوند. بر اساس گزارش‌های رسمی سازمان بهداشت جهانی (WHO)، سالانه بیش از ۳.۱ میلیون نفر در اثر تصادفات جاده‌ای جان خود را از دست می‌دهند و بین ۲۰ تا ۵۰ میلیون نفر دچار آسیب‌های جسمی شدید می‌شوند. تحقیقات آماری نشان می‌دهد که عامل انسانی علت اصلی بیش از ۹۰ درصد از تصادفات جاده‌ای است. در این میان، حواس‌پرتی راننده (Driver\_Distraction) به عنوان کلیدی‌ترین عامل انسانی در بروز سوانح مرگبار شناسایی شده است. حواس‌پرتی راننده به حالت فرآیندی گفته می‌شود که در آن توجه راننده از فعالیت اصلی (یعنی کنترل ایمن وسایل نقلیه و پایش مسیر) به فعالیت‌های ثانویه منحرف می‌گردد. این فعالیت‌های ثانویه طیف وسیعی از رفتارها را شامل می‌شوند که مهم‌ترین آن‌ها عبارتند از:

- استفاده از تلفن همراه: ارسال پیامک، مکالمه با تلفن همراه یا مرور شبکه‌های اجتماعی.
  - دست‌کاری تنظیمات داخل کابین: تنظیم رادیو، سیستم تهویه مطبوع یا دستگاه‌های مسیریاب (GPS).
  - فعالیت‌های شخصی: خوردن، نوشیدن، مرتب کردن مو، آرایش کردن یا صحبت کردن با سرنشینان خودرو.
- انحراف چشم راننده از مسیر حتی به مدت دو ثانیه، احتمال وقوع تصادف را تا دو برابر افزایش می‌دهد. با توجه به توسعه روزافزون فناوری و ورود تجهیزات الکترونیکی گوناگون به کابین خودروها، احتمال بروز حواس‌پرتی در بین رانندگان بیش از گذشته افزایش یافته است. از این رو، طراحی و توسعه سیستم‌های هوشمند شناسایی حواس‌پرتی راننده در لحظه (Real-time\_Driver\_Distraction\_Detection\_Systems) به عنوان یکی از حیاتی‌ترین اجزای سیستم‌های پیشرفته کمک‌راننده (ADAS) و سیستم‌های خودران مطرح شده است.

### ۲.۱ اهمیت و ضرورت موضوع

توسعه سیستم‌های هوشمند پایش وضعیت راننده (Driver\_Monitoring\_Systems-DMS) نه تنها موجب کاهش چشمگیر خسارات جانی و مالی ناشی از تصادفات می‌شود، بلکه مبنایی قانونی و ساختاری برای ارتقای استاندارد ایمنی خودروهای نسل جدید فراهم می‌سازد. سازمان‌های بین‌المللی ارزیابی ایمنی خودرو (Euro\_NCAP) تجهیز خودروهای جدید به سیستم‌های DMS را به عنوان یک الزامی برای دریافت پنج ستاره ایمنی مطرح کرده‌اند. بهره‌گیری از رویکردهای نوین هوش مصنوعی (AI) و به ویژه بینایی ماشین (Computer\_Vision) و یادگیری عمیق (Deep\_Learning)، امکان پردازش خودکار تصاویر دریافتی از دوربین‌های داخل کابین را بدون نیاز به دخالت دست یا نصب حسگرهای فیزیکی دردسرساز بر روی بدن راننده فراهم کرده است. یک سیستم DMS مبتنی بر بینایی ماشین می‌تواند با تحلیل مستمر فرم بدن، جهت نگاه و وضعیت دست‌های راننده، رفتارهای پرخطر را در کسر از ثانیه تشخیص داده و با صدور هشدارهای دیداری یا شنیداری، راننده را به شرایط هوشیاری بازگرداند.

### ۳.۱ چالش‌های فنی بینایی ماشین در داخل کابین خودرو

اگرچه پیاده‌سازی سیستم‌های بینایی ماشین در محیط‌های کنترل‌شده با موفقیت همراه بوده است، اما محیط داخل کابین خودرو یک فضای کاملاً دینامیک و پیچیده محسوب می‌شود که استخراج ویژگی و طبقه‌بندی تصاویر را با چالش‌های اساسی مواجه می‌سازد:

۱. تغییرات شدید نور محیطی: (Illumination\_Changes) تغییرات ناگهانی نور خورشید، سایه‌های شدید درختان و ساختمان‌ها، و شرایط نور ضعیف در شب یا درون تونل‌ها، کیفیت تصاویر ورودی را به شدت تحت تأثیر قرار می‌دهد.

۲. پوشش و انسداد: (Occlusion) قرار گرفتن اشیایی مانند عینک، ماسک، کلاه یا پوشانده شدن دست‌ها و صورت توسط فرمان و اشیای دیگر، استخراج ویژگی‌های کلیدی بدن را دشوار می‌سازد.

۳. تشابه بالای بین‌کلاسی و تنوع درون‌کلاسی: (High\_Intra-class\_Variance\_\_&\_\_Inter-class\_Similarity) برخی از رفتارها (مانند نگاه کردن به رادیو و صحبت با سرنشین کنار) از نظر زاویه سر و دست بسیار به یکدیگر نزدیک هستند؛ در حالی که افراد مختلف ممکن است یک رفتار واحد (مانند پیامک زدن) را با ویژگی‌ها و استایل‌های متفاوتی اجرا کنند.

۴. محدودیت‌های سخت‌افزاری پردازش در لحظه: (Real-time\_Constraints) سیستم‌های پردازش درون خودرویی (Embedded\_Edge\_Devices) معمولاً دارای منابع پردازشی و حافظه محدود هستند؛ بنابراین مدل‌های طراحی شده باید علاوه بر دقت بالا، توانایی پردازش با نرخ فریم بالا (FPS) را داشته باشند.

### ۴.۱ اهداف پژوهش و روش‌شناسی پیشنهادی

هدف اصلی این پژوهش، ارائه، ارزیابی و مقایسه جامع مدل‌های عمیق بینایی ماشین جهت طبقه‌بندی دقیق رفتارهای مختلف راننده بر روی مجموعه داده استاندارد State\_Farm\_Distracted\_Driver\_Detection می‌باشد. این مجموعه داده شامل تصاویر واقعی از رانندگان مختلف در ۱۰ کلاس رفتاری متفاوت است.

برای پوشش دادن چالش‌های مذکور و رسیدن به یک تحلیل دقیق مهندسی، دو معماری شاخص و مدرن از شبکه‌های عصبی پیچشی (CNN) با رویکرد یادگیری انتقالی (Transfer\_Learning) انتخاب و پیاده‌سازی شده‌اند:

۱. شبکه: ResNet۵۰ به عنوان نماینده‌ای از شبکه‌های عمیق با اتصالات باقیمانده (Residual\_Connections) که قادر به استخراج ویژگی‌های بسیار پیچیده و انتزاعی با بالاترین سطح دقت ممکن می‌باشد.

۲. شبکه: MobileNetV۲ به عنوان نماینده‌ای از شبکه‌های سبک و بهینه‌شده برای لبه (Edge\_Devices) که از کانولوشن‌های تفکیک‌پذیر عمقی استفاده کرده و تعادلی فوق‌العاده میان دقت و سرعت پردازش ایجاد می‌کند.

همچنین در این پژوهش، یک استراتژی آموزش دو مرحله‌ای شامل فاز استخراج ویژگی (Feature\_Extraction) و فاز تنظیم دقیق (Fine-Tuning) به همراه نرخ‌های یادگیری قابل تنظیم پیاده‌سازی شده است تا حداکثر کارایی مدل‌ها بر روی داده‌های اعتبارسنجی ثبت گردد.

## ۲ مرور ادبیات و کارهای مرتبط

### ۱.۲ مقدمه

تشخیص رفتارهای پرخطر و حواس‌پرتی رانندگان موضوعی است که در طول دو دهه گذشته توجه گسترده‌ای از پژوهشگران حوزه‌های بینایی ماشین، هوش مصنوعی و سیستم‌های حمل‌ونقل هوشمند را به خود جلب کرده است. بررسی سیر تحول رویکردهای پیشنهادی نشان می‌دهد که این حوزه از الگوریتم‌های مبتنی بر ویژگی‌های دستی و مدل‌های یادگیری ماشین سنتی به سمت استفاده از شبکه‌های عصبی عمیق و معماری‌های پیشرفته کانولوشنی و بینایی مبتنی بر ترنسفورمر حرکت کرده است. در این فصل، ابتدا به بررسی روش‌های اولیه و سنتی بینایی ماشین در تشخیص حواس‌پرتی پرداخته می‌شود؛ سپس سیر ورود یادگیری عمیق به این مسئله و تحقیقات انجام‌شده بر روی مجموعه داده‌های مرجع به‌ویژه مجموعه داده State\_Farm مرور شده و در نهایت تفاوت رویکردهای سنگین در برابر مدل‌های سبک تحلیل می‌گردد.

### ۲.۲ روش‌های سنتی پردازش تصویر و یادگیری ماشین

در نسل اول سیستم‌های پایش راننده، استخراج ویژگی از تصاویر یا ویدیوهای داخل کابین متکی بر تعاریف هندسی یا استخراج‌کننده‌های ویژگی دست‌ساز بود. روش‌های رایج در این دوره عمدتاً شامل مراحل زیر می‌شدند:

۱. شناسایی و آشکارسازی مناطق کلیدی بدن: (ROI\_Extraction) ابتدا با الگوریتم‌هایی نظیر تفریق پس‌زمینه یا فیلترهای رنگ پوست، نواحی سر، چشمان و دست‌های راننده تفکیک می‌شدند.

۲. استخراج توصیف‌گرهای استاتیک و دینامیک:

- توصیف‌گر HOG: (Histogram\_of\_Oriented\_Gradients) برای توصیف لبه‌ها و ساختار هندسی صورت و دست‌ها استفاده می‌شد.

- توصیف‌گر SIFT/SURF: جهت‌شناسایی نقاط کلیدی مقاوم به مقیاس و چرخش.

- ویژگی‌های هارلیک: (Haralick\_Features) برای تحلیل بافت تصویر در نواحی دست یا فرمان.

۳. طبقه‌بندی با الگوریتم‌های کلاسیک: ویژگی‌های استخراج‌شده به عنوان ورودی به طبقه‌بندی‌کننده‌هایی مانند ماشین بردار پشتیبان، (SVM) جنگل‌های تصادفی (Random\_Forests) یا نزدیک‌ترین-K همسایه (k-NN) داده می‌شدند.

#### ۱.۲.۲ محدودیت‌های روش‌های سنتی

اگرچه روش‌های سنتی پیچیدگی محاسباتی کمتری داشتند، اما در سناریوهای دنیای واقعی با چالش‌های بنیادی مواجه می‌شدند:

- حساسیت بالا به نور و سایه: تغییرات نور خورشید در داخل کابین موجب شکست فیلترهای رنگ پوست و خراب شدن توصیف‌گرهای لبه می‌شد.

- عدم تعمیم‌پذیری به افراد مختلف: دست‌ساز بودن ویژگی‌ها باعث می‌شد مدل‌ها نسبت به تغییر جثه، نوع پوشش یا زاویه نشستن رانندگان جدید حساسیت زیادی داشته باشند.
- تکیدگی روی ویژگی‌های سطح پایین: الگوریتم‌های کلاسیک توانایی درک روابط مفهومی پیچیده (مانند رابطه بین زاویه سر، وضعیت دست و وجود جسمی مانند گوشی در دست) را نداشتند.

## ۳.۲ سقوط روش‌های سنتی و ظهور یادگیری عمیق

با معرفی شبکه AlexNet در سال ۲۰۱۲ و جهش چشمگیر در توان پردازشی کارت‌های گرافیک (GPU) شبکه‌های عصبی پیچشی (CNN) حوزه بینایی ماشین را دگرگون ساختند. ویژگی کلیدی شبکه‌های کانولوشنی، یادگیری خودکار ویژگی‌ها از داده‌های خام بدون نیاز به استخراج دستی ویژگی بود. در مسئله تشخیص حواس‌پرتی راننده، شبکه‌های عمیق قادر هستند لایه‌های ابتدایی خود را به استخراج لبه‌ها و بافت‌ها اختصاص دهند و در لایه‌های عمیق‌تر، مفاهیم انتزاعی نظیر شکل دست روی گوشی تلفن، وضعیت صورت هنگام صحبت یا حالت چشم‌ها را استخراج کنند.

## ۴.۲ مرور پژوهش‌های برجسته بر روی مجموعه داده Farm State

انتشار مجموعه داده State\_Farm\_Distracted\_Driver\_Detection در پلتفرم Kaggle در سال ۲۰۱۶، یک نقطه عطف در تحقیقات این حوزه ایجاد کرد. این مجموعه داده با ارائه تصاویر رنگی با کیفیت بالا در ۱۰ کلاس مختلف، بستری استاندارد برای ارزیابی الگوریتم‌های یادگیری عمیق فراهم نمود.

### ۱.۴.۲ استفاده از معماری‌های پایه CNN و یادگیری انتقالی

نخستین پژوهش‌ها بر روی این داده‌ها عمدتاً بر پایه استفاده از شبکه VGG۱۶ و VGG۱۹ شکل گرفت. به عنوان مثال، Yan et al. نشان دادند که با اعمال یادگیری انتقالی (Transfer\_Learning) از وزن‌های آموزش‌دیده روی ImageNet، می‌توان دقت طبقه‌بندی را به بالای ۹۰٪ رساند. با این حال، حجم بالای پارامترها در شبکه VGG (بیش از ۱۳۸ میلیون پارامتر) نرخ فریم بسیار پایینی را در پردازش در لحظه ارائه می‌داد.

در پژوهش‌های بعدی، استفاده از معماری‌های با اتصالات باقیمانده نظیر ResNet۵۰ و ResNet۱۰۱ مورد توجه قرار گرفت. Aboah et al. با به کارگیری شبکه ResNet۵۰ و استفاده از تکنیک‌های افزایش داده پیشرفته مانند برش تصادفی و تغییر درخشش، توانستند دقت اعتبارسنجی را تا محدوده ۹۸٪ افزایش دهند. اتصالات باقیمانده در ResNet مانع از انتشار نامناسب گرادینان در لایه‌های عمیق شده و امکان یادگیری ویژگی‌های تفکیک‌پذیرتر را فراهم می‌ساخت.

### ۲.۴.۲ توسعه معماری‌های سبک و بهینه‌سازی برای سیستم‌های Embedded

با نیاز صنایع خودروسازی به پیاده‌سازی سیستم‌های DMS روی سخت‌افزارهای کم‌مصرف و بردهای هوشمند داخل خودرو (NVIDIA\_Jetson یا Raspberry\_Pi)، توجه پژوهشگران به سمت شبکه‌های سبک معطوف شد:

- MobileNet: Koesdwiady et al. با پیاده‌سازی MobileNetV۲ بر روی داده‌های State\_Farm نشان دادند که با کاهش بیش از ۸۰ درصدی پارامترها نسبت به ResNet، می‌توان به دقتی بیش از ۹۴٪ دست یافت.



• SqueezeNet و ShuffleNet: برخی پژوهشگران از عملیات کانولوشن گروهی و مکانیزم Channel\_Shuffle برای کاهش پیچیدگی محاسباتی استفاده کردند.

## ۳.۴.۲ رویکردهای تلفیقی و ترنسفورمرهای بینایی

در سال‌های اخیر، استفاده از تکنیک‌های پیشرفته‌تر مانند ترکیب شبکه‌های کانولوشنی با شبکه‌های بازگشتی (CNN-LSTM) برای پردازش ویدیو و همچنین استفاده از Self-Attention در ترنسفورمرهای بینایی (Vision\_Transformers-ViT) مطرح شده است. اگرچه ترنسفورمرها در صورت وجود حجم بسیار عظیم داده‌ها دقت‌های عالی ثبت می‌کنند، اما حجم محاسباتی بالا و نیاز به حافظه زیاد، همچنان مانعی برای کاربرد عملی آن‌ها در پردازش‌های در لحظه درون خودرویی محسوب می‌شود.

## ۵.۲ مقایسه و جمع‌بندی ادبیات تحقیق

جدول ۱.۲ خلاصه‌ای از پژوهش‌های شاخص انجام‌شده در زمینه تشخیص حواس‌پرتی راننده با رویکردهای مختلف را نشان می‌دهد.

جدول ۱.۲: مقایسه پژوهش‌های برجسته در حوزه تشخیص حواس‌پرتی راننده

| پژوهشگران         | سال  | معماری/روش   | مجموعه داده    | دقت (%) | ویژگی/محدودیت اصلی      |
|-------------------|------|--------------|----------------|---------|-------------------------|
| Streiffer et al.  | ۲۰۱۷ | VGG-16       | Farm State     | ۴۰.۹۲   | حجم محاسباتی بالا، کند  |
| Baheti et al.     | ۲۰۱۸ | VGG-16 + Aug | Farm State     | ۳۱.۹۶   | مقاوم‌تر به تغییرات نور |
| Aboah et al.      | ۲۰۲۰ | ResNet-50    | Farm State     | ۶۰.۹۸   | دقت بالا، استخراج عالی  |
| Majdi et al.      | ۲۰۲۱ | DriveNet     | Distracted AUC | ۱۰.۹۴   | معماری سفارشی سبک       |
| Al-Maimani et al. | ۲۰۲۲ | MobileNetV2  | Farm State     | ۸۰.۹۴   | بسیار سریع، مناسب Edge  |
| Zhang et al.      | ۲۰۲۳ | ViT-Base     | Farm State     | ۹۰.۹۸   | دقت بالا، پیچیدگی سنگین |

## ۶.۲ نتیجه‌گیری و جایگاه پژوهش حاضر

مرور ادبیات تحقیق نشان می‌دهد که دو چالش حیاتی در این حوزه همچنان وجود دارد:

۱. \*\*ایجاد تعادل بهینه میان دقت و سرعت پردازش.\*\*

۲. \*\*جلوگیری از Overfitting و بهبود تعمیم‌پذیری مدل‌ها در استراتژی‌های یادگیری انتقالی.\*\*

پژوهش حاضر با تمرکز بر دو الگوی نمادین در این حوزه یعنی ResNet۵۰ (نماینده مدل‌های بسیار دقیق و عمیق) و MobileNetV۲ (نماینده مدل‌های سریع و فشرده) به پیاده‌سازی یک خط لوله آموزش دو مرحله‌ای Feature\_Extraction و Fine-Tuning روی داده‌های State\_Farm می‌پردازد تا ضمن تحلیل دقیق رفتاری هر دو مدل، ارزیابی جامعی از جنبه‌های عملیاتی آن‌ها ارائه دهد.

## ۳ مبانی نظری و فرمول‌بندی ریاضی

### ۱.۳ مقدمه

در این فصل، مبانی نظری و زیرساخت‌های ریاضی شبکه‌های عصبی عمیق استفاده‌شده در این پژوهش تشریح می‌گردد. ابتدا مفاهیم پایه شبکه‌های کانولوشنی (CNNs) شامل لایه‌های کانولوشن، تجمع (Pooling) و توابع فعال‌سازی فرمول‌بندی می‌شوند. سپس ریاضیات مربوط به معماری‌های پیشرفته ResNet۵۰ (مبتنی بر اتصالات باقیمانده) و MobileNetV۲ (مبتنی بر کانولوشن‌های تفکیک‌پذیر) به صورت تفصیلی تحلیل خواهد شد. در نهایت، توابع زیان و الگوریتم‌های بهینه‌سازی مورد استفاده برای آموزش شبکه‌ها بررسی می‌شوند.

### ۲.۳ مبانی شبکه‌های عصبی پیچشی (CNN)

شبکه‌های عصبی پیچشی رده‌ای از شبکه‌های عمیق پیش‌سو هستند که عمدتاً برای پردازش داده‌های شبکه‌ای مانند تصاویر دوبعدی طراحی شده‌اند.

#### ۱.۲.۳ عملگر کانولوشن دوبعدی (۲D\_Convolution)

فرض کنید تصویر ورودی با  $I \in \mathbb{R}^{H \times W \times C_{in}}$  نشان داده شود که در آن  $H$ ،  $W$  و  $C_{in}$  به ترتیب ارتفاع، عرض و تعداد کانال‌های ورودی (مثلاً ۳ کانال برای RGB) هستند. فیلتر کانولوشن (کرnel) به صورت  $K \in \mathbb{R}^{k \times k \times C_{in} \times C_{out}}$  تعریف می‌شود که  $k$  اندازه کرnel و  $C_{out}$  تعداد فیلترها (کانال‌های خروجی) است.

مقدار نورون در موقعیت  $(i, j)$  از کانال خروجی  $c$  به صورت زیر محاسبه می‌شود:

$$Y(i, j, c) = b_c + \sum_{m=-\frac{k-1}{2}}^{\frac{k-1}{2}} \sum_{n=-\frac{k-1}{2}}^{\frac{k-1}{2}} \sum_{l=1}^{C_{in}} I(i+m, j+n, l) \cdot K(m, n, l, c) \quad (۱.۳)$$

که در آن  $b_c$  مقدار تورش (Bias) مربوط به کانال  $c$  است.

اگر گام حرکتی (Stride) برابر با  $S$  و میزان پدینگ (Padding) برابر با  $P$  باشد، ابعاد نقشه ویژگی خروجی  $(H_{out} \times W_{out})$  به صورت زیر تغییر می‌یابد:

$$H_{out} = \left\lfloor \frac{H - k + 2P}{S} \right\rfloor + 1, \quad W_{out} = \left\lfloor \frac{W - k + 2P}{S} \right\rfloor + 1 \quad (۲.۳)$$

#### ۲.۲.۳ لایه‌های کاهش بعد (Pooling\_Layers)

لایه‌های Pooling برای کاهش ابعاد فضایی نقشه‌های ویژگی و ایجاد مقاومت نسبت به جابه‌جایی کوچک (Translation Invariance) به کار می‌روند. در این پژوهش از دو نوع Pooling استفاده شده است:

۱. Max\_Pooling: بیشترین مقدار را در یک پنجره متحرک  $p \times p$  انتخاب می‌کند:

$$Y_{max}(i, j) = \max_{m, n \in [0, p-1]} X(i \cdot S + m, j \cdot S + n) \quad (3.3)$$

۲. Global\_Average\_Pooling\_(GAP): کل نقشه ویژگی هر کانال را به یک عدد میانگین تقلیل می‌دهد. برای نقشه ویژگی  $X_c$  با ابعاد  $H \times W$ :

$$GAP(X_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W X_c(i, j) \quad (4.3)$$

استفاده از GAP به جای لایه‌های Fully\_Connected متراکم، تعداد پارامترهای مدل را به شدت کاهش داده و از بیش‌برازش (*Over fitting*) جلوگیری می‌کند.

### ۳.۲.۳ توابع فعال‌سازی (Activation\_Functions)

برای ورود غیرخطی‌سازی به شبکه، از توابع فعال‌سازی زیر استفاده می‌شود:

• تابع ReLU\_(Rectified\_Linear\_Unit)

$$f(x) = \max(0, x) \quad (5.3)$$

• تابع ReLU۶ (مورد استفاده در *MobileNetV2*): محدود کردن دامنه خروجی به عددی بین ۰ تا ۶ جهت حفظ پایداری محاسبات در سخت‌افزارهای کم‌مصرف:

$$\text{ReLU}_6(x) = \min(\max(0, x), 6) \quad (6.3)$$

• تابع Softmax (برای لایه خروجی): تبدیل خروجی‌های خام شبکه (*Logits*) به توزیع احتمالی بین ۱۰ کلاس حواس‌پرتی:

$$P(y = c | \mathbf{x}) = \frac{e^{z_c}}{\sum_{j=1}^K e^{z_j}}, \quad c \in \{1, 2, \dots, K\} \quad (7.3)$$

که  $K = 10$  تعداد کلاس‌ها و  $z_c$  مقدار خروجی خام مربوط به کلاس  $c$  است.


## ۳.۳ معماری ResNet۵۰ و اتصالات باقیمانده

با عمیق‌تر شدن شبکه‌های عصبی کلاسیک، مسئله محو شدگی گرادیان (*VanishingGradient*) رخ می‌دهد؛ به طوری که هنگام پس‌انتشار (*Backpropagation*)، گرادیان خطای لایه‌های پایانی در حین عبور از لایه‌های متوالی به صفر نزدیک شده و لایه‌های ابتدایی آموزش نمی‌بینند.

### ۱.۳.۳ مفهوم یادگیری باقیمانده (Residual\_Learning)

معماری ResNet با معرفی اتصالات میان‌بر (*Shortcut/SkipConnections*) این مشکل را حل نمود. فرض کنید نگاهی که مورد نظر برای یک یا چند لایه متوالی به صورت  $H(\mathbf{x})$  باشد. شبکه ResNet به جای یادگیری مستقیم  $H(\mathbf{x})$ ، تابع باقیمانده  $F(\mathbf{x}) := H(\mathbf{x}) - \mathbf{x}$  را بهینه‌سازی می‌کند. در نتیجه خروجی لایه به صورت زیر بازنویسی می‌شود:

$$\mathbf{y} = F(\mathbf{x}, \{W_i\}) + \mathbf{x} \quad (8.3)$$



شکل ۱.۳: بلاک ساختاری باقیمانده (ResidualBlock) در شبکه ResNet

مزیت اصلی این روش در پسانتشار مشخص می‌شود. مشتق زیان ( $L$ ) نسبت به ورودی  $x$  طبق قاعده زنجیره‌ای عبارت است از:

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial x} = \frac{\partial L}{\partial y} \left( \frac{\partial F(x, \{W_i\})}{\partial x} + 1 \right) \quad (9.3)$$

عبارت  $+1$  تضمین می‌کند که حتی اگر مشتق لایه‌های وزن‌دار  $\frac{\partial F}{\partial x}$  برابر با صفر شود، گرادینان  $\frac{\partial L}{\partial y}$  بدون تضعیف مستقیماً به لایه‌های قبلی منتقل می‌گردد.

### ۲.۳.۳ بلاک گلوگاه (Bottleneck Architecture)

شبکه ResNet۵۰ از «بلاک‌های گلوگاه» ۳ لایه‌ای بهره می‌برد. برای یک ورودی با ابعاد مشخص، لایه‌ها به صورت زیر عمل می‌کنند:

۱. کانولوشن  $1 \times 1$  برای کاهش بعد (کاهش تعداد کانال‌ها به یک چهارم).
۲. کانولوشن  $3 \times 3$  برای استخراج ویژگی‌های فضایی.
۳. کانولوشن  $1 \times 1$  برای افزایش مجدد بعد (بازگرداندن تعداد کانال‌ها به حالت اولیه).

## ۴.۳ معماری MobileNetV۲ و بهینه‌سازی محاسباتی

شبکه MobileNetV۲ برای اجرا روی تجهیزات سخت‌افزاری محدود طراحی شده است. کلید اصلی موفقیت این شبکه، کاهش پیچیدگی محاسباتی با جایگزینی کانولوشن استاندارد با کانولوشن تفکیک‌پذیر عمقی است.

### ۱.۴.۳ کانولوشن تفکیک‌پذیر عمقی (Depthwise\_Separable\_Convolution)

کانولوشن تفکیک‌پذیر، یک عملیات کانولوشن استاندارد را به دو گام مجزا تقسیم می‌کند:

۱. Depthwise\_Convolution\_(DW): اعمال یک فیلتر  $k \times k$  مجزا روی هر کانال ورودی به صورت مستقل.
۲. Pointwise\_Convolution\_(PW): اعمال کانولوشن  $1 \times 1$  روی تمام کانال‌ها برای ترکیب خطی ویژگی‌ها.

تحلیل هزینه محاسباتی (Computational\_Cost)

فرض کنید ورودی با ابعاد  $D_F \times D_F \times M$  و فیلترها با ابعاد  $k \times k \times M \times N$  باشند:

• هزینه کانولوشن استاندارد ( $Cost_{std}$ ):

$$Cost_{std} = D_F \cdot D_F \cdot M \cdot N \cdot k \cdot k \quad (۱۰.۳)$$

• هزینه کانولوشن تفکیک پذیر عمقی ( $Cost_{dws}$ ):

$$Cost_{dws} = \underbrace{D_F \cdot D_F \cdot M \cdot k \cdot k}_{\text{Depthwise}} + \underbrace{D_F \cdot D_F \cdot M \cdot N}_{\text{Pointwise}} \quad (۱۱.۳)$$

نسبت کاهش محاسبات برابر است با:

$$\frac{Cost_{dws}}{Cost_{std}} = \frac{D_F^2 \cdot M \cdot k^2 + D_F^2 \cdot M \cdot N}{D_F^2 \cdot M \cdot N \cdot k^2} = \frac{1}{N} + \frac{1}{k^2} \quad (۱۲.۳)$$

برای یک کرنل  $3 \times 3$  ( $k = 3$ )، این عملیات حجم محاسبات را حدود ۸ تا ۹ برابر نسبت به کانولوشن معمولی کاهش می دهد.

### ۲.۴.۳ بلاک باقیمانده معکوس (Inverted\_Residual\_Block)

برعکس بلاک های سنتی ResNet که ابتدا بعد را کاهش داده و سپس افزایش می دهند، MobileNetV۲ از ساختار Inverted\_Residuals استفاده می کند:

۱. Expansion\_Layer (کانولوشن  $1 \times 1$ ): افزایش تعداد کانال ها با ضریب توسیع  $t$  ( $t = 6$  به صورت پیش فرض) جهت حفظ اطلاعات در فضای ابعاد بالا.

۲. Depthwise\_Layer (کانولوشن  $3 \times 3$ ): استخراج ویژگی فضایی.

۳. Projection\_Layer (کانولوشن  $1 \times 1$  یا  $Linear Bottleneck$ ): کاهش مجدد تعداد کانال ها بدون استفاده از تابع غیرخطی در لایه آخر (حفظ اطلاعات خطی).

## ۵.۳ تابع زیان و الگوریتم بهینه سازی

### ۱.۵.۳ تابع زیان انتروپی متقاطع (Categorical\_Cross\_Entropy\_Loss)

با توجه به ۱۰ کلاس بودن مسئله تشخیص حواس پرتی راننده، از تابع زیان Categorical\_Cross\_Entropy استفاده می شود. برای یک نمونه آموزشی با برچسب واقعی  $y$  (به صورت بردار  $One - Hot$ ) و پیش بینی مدل  $\hat{y}$ ، مقدار زیان برابر است با:

$$\mathcal{L}_{CE} = - \sum_{c=1}^K y_c \log(\hat{y}_c) \quad (۱۳.۳)$$

برای یک Batch از داده ها با اندازه  $N$ :

$$\mathcal{L}_{total} = - \frac{1}{N} \sum_{i=1}^N \sum_{c=1}^K y_{i,c} \log(\hat{y}_{i,c}) \quad (۱۴.۳)$$

### ۲.۵.۳ بهینه‌ساز Adam\_(Adaptive\_Moment\_Estimation)

برای به‌روزرسانی پارامترهای شبکه  $(\theta)$ ، الگوریتم بهینه‌سازی Adam به کار گرفته شده است که ممان‌های مرتبه اول و دوم گرادیان را تخمین می‌زند:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (\text{تخمین ممان اول - میانگین}) \quad (15.3)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (\text{تخمین ممان دوم - واریانس غیر متمرکز}) \quad (16.3)$$

اصلاح انحراف (*Bias Correction*) برای گام‌های ابتدایی:

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (17.3)$$

قاعده به‌روزرسانی پارامترها:

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t \quad (18.3)$$

که در آن  $\eta$  نرخ یادگیری (*Learning Rate*)،  $\beta_1 = 0.9$ ،  $\beta_2 = 0.999$  و  $\epsilon = 10^{-7}$  مقادیر پیش‌فرض تنظیم شده هستند.

## ۶.۳ جمع‌بندی فصل

در این فصل پایه‌های ریاضی و ساختار لایه‌های کانولوشن، اتصالات باقیمانده در ResNet۵۰ و بهینه‌سازی‌های محاسباتی کانولوشن تفکیک‌پذیر در MobileNetV۲ تبیین شد. فرمول‌بندی توابع فعال‌سازی و تابع زیان انتروپی متقاطع در کنار بهینه‌ساز Adam، چارچوب نظری کامل برای درک عملکرد کد پیاده‌سازی شده در فصل‌های آتی را فراهم می‌سازد.

## ۴ تحلیل مجموعه داده و پیش پردازش

### ۱.۴ مقدمه

موفقیت مدل‌های یادگیری عمیق در بینایی ماشین وابستگی مستقیمی به کیفیت، تنوع و نحوه پیش پردازش مجموعه داده ورودی دارد. در مسئله حساس تشخیص حواس پرتی راننده، مدل باید بتواند الگوهای بصری پیچیده را در شرایط محیطی گوناگون فرا بگیرد.

در این فصل، ابتدا مجموعه داده مرجع *StateFarmDistractedDriverDetection* معرفی شده و جزئیات ۱۰ کلاس رفتاری آن تحلیل می‌گردد. سپس ساختار تقسیم‌بندی داده‌ها، روش‌های افزایش داده (*Data Augmentation*) و در نهایت الزامات نرمال‌سازی و پیش پردازش اختصاصی برای دو معماری *ResNet50* و *MobileNetV2* تشریح خواهد شد.

### ۲.۴ معرفی مجموعه داده Farm State


مجموعه داده *State Farm* یکی از معتبرترین پایگاه‌های داده تصویری در حوزه پایش رفتار راننده است که توسط شرکت بیمه *State Farm* بر روی پلتفرم *Kaggle* منتشر شده است. این مجموعه شامل تصاویر رنگی (*RGB*) با تفکیک پذیری  $640 \times 480$  پیکسل است که از زاویه دید بالای داشبورد (سمت راست راننده) ثبت شده‌اند. تصاویر این پایگاه داده، رانندگان مختلف با ویژگی‌های جثه‌ای، جنسیت و پوشش متفاوت را در حال انجام فعالیت‌های مختلف نشان می‌دهد. کلاس‌های این مجموعه داده به ۱۰ دسته استاندارد *c0* تا *c9* تقسیم می‌شوند که در جدول ۱.۴ مشخص شده‌اند.

جدول ۱.۴: کلاس‌های رفتار راننده در مجموعه داده *State\_Farm*

| شناسه کلاس | عنوان انگلیسی                | توصیف رفتار راننده                        |
|------------|------------------------------|-------------------------------------------|
| <i>c0</i>  | Safe driving                 | رانندگی ایمن و طبیعی (توجه کامل به مسیر)  |
| <i>c1</i>  | Texting - right              | پیامک زدن با دست راست                     |
| <i>c2</i>  | Talking on the phone - right | صحبت با تلفن همراه با دست راست (کنار گوش) |
| <i>c3</i>  | Texting - left               | پیامک زدن با دست چپ                       |
| <i>c4</i>  | Talking on the phone - left  | صحبت با تلفن همراه با دست چپ (کنار گوش)   |
| <i>c5</i>  | Operating the radio          | دست‌کاری و تنظیم رادیو / ضبط خودرو        |
| <i>c6</i>  | Drinking                     | خوردن یا نوشیدن                           |
| <i>c7</i>  | Reaching behind              | برداشتن وسیله از صندوق عقب                |
| <i>c8</i>  | Hair and makeup              | مرتب کردن مو یا آرایش کردن                |
| <i>c9</i>  | Talking to passenger         | صحبت کردن و برگشتن به سمت سرنشین کنار     |




FULL EDA - STATE FARM DATASET




شکل ۱.۴: داشبورد جامع تحلیل اکتشافی داده‌ها (EDA) شامل توزیع کلاس‌ها، پراکندگی رانندگان، ارزیابی کیفیت بصری و همبستگی ویژگی‌های تصویر

## Visual Samples by Class - State Farm Dataset

c0: Normal driving




c1: Texting - right




c2: Talking on phone - right





شکل ۲.۴: نمونه‌های بصری منتخب از ۱۰ حالت رفتاری راننده در مجموعه داده Farm State (۴ نمونه تصویر به ازای هر کلاس)



شکل ۳.۴: ماتریس شباهت بصری بین کلاس‌های ۱۰ گانه بر اساس فاصله کسینوسی هیستوگرام‌های RGB

مطابق ماتریس شباهت شکل ۳.۴، مقدار شباهت کسینوسی بین توزیع رنگی برخی کلاس‌ها به بالاتر از ۰/۹۵ می‌رسد. این همبستگی بالا نشان می‌دهد که تصمیم‌گیری صرف بر اساس رنگ و بافت کلی تصویر کافی نیست و شبکه باید ویژگی‌های عمیق‌تر و ساختاری دست‌ها و اشیاء را فراگیرد.

## ۳.۴ تحلیل آماری و ساختار داده‌ها

مجموعه داده آموزش در این پروژه شامل مجموعاً ۲۲،۴۲۴\*\* تصویر برچسب‌گذاری شده\*\* است. برای ارزیابی دقیق و جلوگیری از تورش مدل، داده‌ها به دو بخش زیر تقسیم شده‌اند:

- مجموعه آموزش (*TrainingSet*): ۱۷،۹۳۹ تصویر (حدود ۸۰٪ از کل داده‌ها) برای به‌روزرسانی وزن‌های شبکه.
- مجموعه اعتبارسنجی (*ValidationSet*): ۴،۴۸۵ تصویر (حدود ۲۰٪ از کل داده‌ها) برای ارزیابی پایداری و تنظیم هایپرپارامترها.

توزیع نمونه‌ها در میان کلاس‌های ۱۰ گانه نسبتاً متوازن (*Balanced*) است که این امر مانع از غلبه یک کلاس خاص در طول فرآیند آموزش می‌شود. جدول ۲.۴ آمار دقیق تصاویر در هر کلاس را نشان می‌دهد.



جدول ۲.۴: توزیع فراوانی تصاویر به تفکیک کلاس‌ها در مجموعه‌های آموزش و اعتبارسنجی

| کلاس  | شرح مختصر      | تعداد آموزش (Train) | تعداد اعتبارسنجی (Val) | مجموع  |
|-------|----------------|---------------------|------------------------|--------|
| c0    | رانندگی ایمن   | ۱,۸۳۱               | ۴۵۸                    | ۲,۲۸۹  |
| c1    | پیامک راست     | ۱,۸۰۹               | ۴۵۸                    | ۲,۲۶۷  |
| c2    | تلفن راست      | ۱,۸۴۶               | ۴۶۱                    | ۲,۳۰۷  |
| c3    | پیامک چپ       | ۱,۸۷۷               | ۴۶۹                    | ۲,۳۴۶  |
| c4    | تلفن چپ        | ۱,۸۵۰               | ۴۶۲                    | ۲,۳۱۲  |
| c5    | تنظیم رادیو    | ۱,۸۴۹               | ۴۶۳                    | ۲,۳۱۲  |
| c6    | خوردن/نوشیدن   | ۱,۸۶۰               | ۴۶۵                    | ۲,۳۲۵  |
| c7    | دست به عقب     | ۱,۵۲۹               | ۳۸۳                    | ۱,۹۱۲  |
| c8    | مو و آرایش     | ۱,۵۳۰               | ۳۸۱                    | ۱,۹۱۱  |
| c9    | صحبت با سرنشین | ۱,۷۲۵               | ۴۳۱                    | ۲,۱۵۶  |
| مجموع | -              | ۱۷,۹۳۹              | ۴,۴۸۵                  | ۲۲,۴۲۴ |

Train: img\_60621.jpg  
class: c9



Test: img\_99787.jpg



Train: img\_4617.jpg  
class: c7



Test: img\_99702.jpg



Train: img\_4463.jpg  
class: c7



Test: img\_77344.jpg



Train: img\_75902.jpg  
class: c1


Test: img\_69909.jpg


Train: img\_96395.jpg  
class: c5


Test: img\_33766.jpg


Train: img\_75902.jpg  
class: c1


Test: img\_64453.jpg



شکل ۴.۴: نمونه‌هایی از جفت تصاویر مشابه در مجموعه‌های آموزش (Train) و آزمون (Test) که نشان‌دهنده نشت داده‌ها (Data Leakage) در تقطیع تصادفی است.

یکی از چالش‌های بنیادین در مجموعه‌داده State Farm Distracted Driver Detection، حضور یک راننده مشخص در چندین فریم پیاپی است. در صورتی که تقسیم‌بندی داده‌ها به صورت کاملاً تصادفی انجام شود، تصاویری از یک راننده واحد هم در مجموعه آموزش و هم در مجموعه اعتبارسنجی/آزمون قرار می‌گیرند (شکل ۴.۴).

این پدیده که تحت عنوان نشت داده‌ها (Data Leakage) شناخته می‌شود، سبب می‌گردد مدل به جای یادگیری «ویژگی‌های انتزاعی رفتار رانندگی»، «ویژگی‌های دیداری خاص آن راننده» (مانند رنگ لباس، پس‌زمینه خودرو یا زاویه صندلی) را به خاطر

بسیار. این امر منجر به ارزیابی بیش از حد خوش بینانه و کاذب در مرحله اعتبارسنجی می شود. جهت رفع این چالش در فرایند پیاده سازی، تقطیع داده ها بر اساس شناسه رانندگان (Driver ID) و با استفاده از روش GroupKFold انجام شده است تا ارزیابی مدل کاملاً مستقل از هویت رانندگان صورت پذیرد.

## ۴.۴ تکنیک های افزایش داده (Data\_Augmentation)

یکی از چالش های اصلی در آموزش شبکه های عمیق، خطر بیش برازش (*Overfitting*) رو داده های آموزشی است. برای بهبود قدرت تعمیم پذیری (*Generalization*) مدل بر روی تصاویر جدید، از الگوریتم های افزایش خطی و هندسی داده ها در طول بارگذاری استفاده شده است.

### ۱.۴.۴ تغییرات هندسی و رنگی

عملیات ریاضی اعمال شده بر روی تصاویر ورودی شامل موارد زیر است:

۱. چرخش تصادفی (*Random\_Rotation*): اعمال دوران حول مرکز تصویر با زاویه  $\theta \in [-10^\circ, +10^\circ]$ . ماتریس دوران دوبرعده عبارت است از:


$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} x - x_c \\ y - y_c \end{bmatrix} + \begin{bmatrix} x_c \\ y_c \end{bmatrix} \quad (1.4)$$

۲. انتقال افقی و عمودی (*Random\_Translation*): جابه جایی پیکسل ها به اندازه  $t_x, t_y$  تا حداکثر ۱۰٪ ابعاد تصویر:

$$I_{new}(x, y) = I(x - t_x, y - t_y) \quad (2.4)$$

۳. تغییر مقیاس تصادفی (*Random\_Zoom*): بزرگ نمایی یا کوچک نمایی تصویر با ضریب  $s \in [0.9, 1.1]$ .


نکته طراحی مهندسی: به دلیل حیاتی بودن موقعیت دست ها (دست راست یا چپ بودن تلفن/پیامک)، از \*\*بازتاب افقی (*Horizontal\_Flip*) استفاده نشده است؛ زیرا بازتاب افقی کلاس *c1* (پیامک با دست راست) را فرآیندی مشابه *c3* (پیامک با دست چپ) تغییر می دهد و الگوریتم را دچار سردرگمی می کند.



شکل ۵.۴: مقایسه توزیع فراوانی تصاویر کلاس‌های ۱۰ گانه پیش از متوازن‌سازی و پس از اعمال افزون‌سازی تقویت‌شده (رساندن تمام کلاس‌ها به ۲۳۰۰ نمونه)

همان‌طور که در شکل ۵.۴ (سمت چپ) مشاهده می‌شود، ناهمگونی و عدم توازن اولیه در تعداد نمونه‌های کلاس‌های مختلف وجود داشت که می‌توانست موجب سوگیری مدل به سمت کلاس‌های اکثر شود. جهت رفع این چالش، استراتژی متوازن‌سازی هوشمند با اعمال تغییرات هندسی و نوری تقویت‌شده (Strengthened Augmentation) پیاده‌سازی گردید. پارامترهای افزون‌سازی به گونه‌ای تنظیم شدند که ضمن افزایش تنوع داده‌ها، ویژگی‌های حیاتی حفظ شوند. به عنوان مثال، پارامتر چرخش افقی (Horizontal Flip) به صورت دقیق غیرفعال (False) نگه داشته شد؛ زیرا تغییر جهت دست راننده (راست‌دست یا چپ‌دست بودن) ماهیت معنایی کلاس‌ها (مانند تفاوت  $c_1$  و  $c_3$ ) را تغییر می‌دهد. در نهایت، با تولید نمونه‌های سنتیز شده، تمام کلاس‌ها دقیقاً روی تعداد ۲,۳۰۰ تصویر متوازن گردیدند (شکل ۵.۴ سمت راست).


Augmentation Preview - Class c0



شکل ۶.۴: پیش‌نمایش افزون‌سازی برای کلاس  $c_0$  (رانندگی عادی)



Augmentation Preview - Class c8

شکل ۷.۴: پیش‌نمایش افزون‌سازی برای کلاس  $c_8$  (مرتب‌کردن مو/آرایش)

جهت اطمینان از حفظ ماهیت معنایی تصاویر پس از اعمال دگرگونی‌ها، پیش‌نمایش تغییرات برای نمونه‌هایی از کلاس‌های مختلف (شکل ۶.۴ و ۷.۴) مورد بررسی قرار گرفت. مطابق تصاویر خروجی:

- تغییرات نوری و جابه‌جایی‌های جزئی (Shift & Brightness Adjustment) شرایط واقعی متغیر بودن نور داخل کابین خودرو و زوایای مختلف دوربین را به خوبی شبیه‌سازی می‌کنند.
- هندسه اصلی راننده و ابزارهای در دست او (مانند تلفن همراه یا لیوان) تحت تأثیر جابه‌جایی‌ها تخریب نشده و ساختار کلاس کاملاً محفوظ مانده است.

## ۵.۴ تغییر ابعاد و نرمال‌سازی تصاویر ورودی

### ۱.۵.۴ تغییر مقیاس فضایی (Resizing)

تصاویر اصلی با ابعاد  $640 \times 480 \times 3$  جهت کاهش بار محاسباتی و تطابق با استاندارد شبکه به ابعاد زیر تغییر می‌یابند:

$$I_{input} \in \mathbb{R}^{224 \times 224 \times 3} \quad (۳.۴)$$

## ۲.۵.۴ پیش‌پردازش و نرمال‌سازی اختصاصی مدل‌ها

شبکه‌های پیش‌آموزش‌دیده بر روی *ImageNet* نیازمند نرمال‌سازی دقیق پیکسل‌ها مطابق با فرآیند اولیه آموزش خود هستند. در این پروژه دو خط‌لوله پیش‌پردازش متفاوت پیاده‌سازی گردید:

### ۱. پیش‌پردازش در شبکه MobileNetV۲

پیکسل‌های تصویر ورودی که در ابتدا در دامنه  $[0, 255]$  قرار دارند، با استفاده از تابع پیش‌پردازش استاندارد *MobileNet* به دامنه  $[-1, 1]$  نگاشت می‌شوند:

$$x_{norm} = \frac{x}{127.5} - 1.0 \quad \Rightarrow \quad x_{norm} \in [-1.0, 1.0] \quad (۴.۴)$$

### ۲. پیش‌پردازش در شبکه ResNet۵۰

در پیاده‌سازی ارائه شده برای *ResNet50*، لایه پیش‌پردازش اختصاصی 'preprocess\_input' مستقیماً در انتهای خط‌لوله ورودی قرار داده شد. این تابع، کانال‌های رنگی را از *RGB* به *BGR* تبدیل کرده و میانگین شدت روشنایی کانال‌های پایگاه داده *ImageNet* را از آن‌ها کسر می‌کند:

$$\begin{cases} B' = B - 103.939 \\ G' = G - 116.779 \\ R' = R - 123.680 \end{cases} \quad (۵.۴)$$

همچنین مقادیر شدت پیکسل ورودی در دامنه  $[0, 1]$  وارد این لایه اختصاصی می‌گردند.

Sample after preprocessing



شکل ۸.۴: نمونه‌ای از داده‌های ورودی آماده‌شده پس از طی مراحل خط‌لوله پیش‌پردازش (تغییر سایز به  $224 \times 224$ ، نرمال‌سازی دامنه پیکسل‌ها به  $[0, 1]$  و اعمال الگوریتم‌های افزون‌سازی)

جهت اطمینان از صحت عملکرد ژنراتورهای داده (ImageDataGenerator) و آماده‌سازی بسته‌های ورودی (Batches) برای شبکه‌های عمیق، نمونه‌ای از خروجی خط‌لوله در شکل ۸.۴ نمایش داده شده است. همان‌طور که مشخص است، تمامی تصاویر به رزولوشن ورودی استاندارد  $224 \times 224 \times 3$  تبدیل شده، دامنه‌ی بازه مقادیر پیکسل‌ها از  $[0, 255]$  به  $[0, 1]$  نگاشت یافته و برچسب‌های مربوط به هر کلاس به صورت ماتریس‌های One-Hot Encoding تنظیم شده‌اند. این گام، آخرین مرحله از فاز پیش‌پردازش بوده و بستر داده‌ها را برای ورود به مرحله آموزش شبکه‌های ResNet50 و MobileNetV2 آماده می‌سازد.

## ۶.۴ جمع‌بندی فصل

در این فصل ویژگی‌های آمارشناسی مجموعه داده، State\_Farm کلاس‌های ۱۰ گانه و نحوه تقسیم داده‌ها بررسی شد. همچنین اهمیت عدم استفاده از Horizontal\_Flip برای حفظ یکپارچگی برچسب‌های دست چپ/راست تحلیل گردید و معادلات نرمال‌سازی ورودی برای هر دو شبکه MobileNetV۲ و ResNet۵۰ تثبیت شد. این پیش‌پردازش‌های دقیق، زیرساخت ورود داده‌ها به فاز آموزش مدل‌ها در فصل بعدی را تشکیل می‌دهند.

### ۱.۵ مقدمه

پس از تحلیل پایگاه داده و انجام پیش‌پردازش‌های لازم، در این فصل جزئیات معماری‌های پیاده‌سازی شده و خط‌لوله (Pipeline) آموزش شبکه‌ها تشریح می‌گردد. رویکرد اصلی این پژوهش، بهره‌گیری از یادگیری انتقالی (Transfer\_Learning) مبتنی بر وزن‌های پیش‌آموزش دیده بر روی مجموعه داده عظیم ImageNet است. در ادامه، جزئیات لایه‌های سفارشی افزوده شده به بدنه اصلی شبکه‌ها، استراتژی آموزش دو فاز (شامل فاز استخراج ویژگی و فاز تنظیم دقیق)، تنظیم هاپیرپارامترها و مکانیزم‌های کنترلی آموزش مورد تحلیل دقیق قرار می‌گیرند.

### ۲.۵ معماری شبکه و لایه‌های سفارشی (Custom\_Classification\_Head)

برای انطباق وزن‌های پیش‌آموزش دیده شبکه‌های ResNet۵۰ و MobileNetV۲ با مسئله ۱۰ کلاسه تشخیص حواس‌پرتی راننده، لایه‌های انتهایی (Dense\_Head) این شبکه‌ها حذف گردیده و یک سر طبقه‌بندی سفارشی عمیق بر روی آن‌ها جای‌گذاری شده است.

#### ۱.۲.۵ ساختار لایه‌های سفارشی

سر طبقه‌بندی طراحی شده شامل لایه‌های زیر به ترتیب است:

۱. لایه Global\_Average\_Pooling\_۲D\_(GAP): کاهش ابعاد فضایی نقشه ویژگی‌های خروجی از بدنه اصلی به یک بردار یک‌بعدی.
۲. لایه Fully\_Connected اول (Dense): شامل ۵۱۲ نورون با تابع فعال‌سازی  $ReLU$  جهت استخراج نگاشت‌های انتزاعی سطح بالا.
۳. لایه Dropout اول: با نرخ ۰.۵ جهت حذف تصادفی اتصالات در طول آموزش و جلوگیری از بیش‌برازش ( $Overfitting$ ).
۴. لایه Fully\_Connected دوم (Dense): شامل ۲۵۶ نورون با تابع فعال‌سازی  $ReLU$  برای فشرده‌سازی بیشتر ویژگی‌ها.
۵. لایه Dropout دوم: با نرخ ۰.۳ جهت تثبیت بیشتر پایداری شبکه.
۶. لایه خروجی (Dense\_Output\_Layer): شامل ۱۰ نورون با تابع فعال‌سازی  $Softmax$  جهت تولید توزیع احتمالی پیش‌بینی‌ها برای ۱۰ کلاس رفتار راننده.

جدول ۱.۵ خلاصه ساختار لایه‌های سفارشی متصل شده به انتهای هر دو بدنه اصلی را نشان می‌دهد.


جدول ۱.۵: ساختار لایه‌های سفارشی سر طبقه‌بندی (Custom\_Classification\_Head)

| نام لایه           | نوع لایه        | ابعاد خروجی / تعداد نوروں | تابع فعال‌سازی / پارامتر |
|--------------------|-----------------|---------------------------|--------------------------|
| Base Model Output  | -               | $H \times W \times C$     | -                        |
| GlobalAvgPooling2D | Pooling         | $C$                       | -                        |
| Dense 1            | Connected Fully | ۵۱۲                       | ReLU                     |
| Dropout 1          | Regularization  | ۵۱۲                       | ۰/۵ = Rate               |
| Dense 2            | Connected Fully | ۲۵۶                       | ReLU                     |
| Dropout 2          | Regularization  | ۲۵۶                       | ۰/۳ = Rate               |
| Output Dense       | Connected Fully | ۱۰                        | Softmax                  |

## ۲.۲.۵ معماری شبکه پیشنهادی مبتنی بر MobileNetV۲

جهت استخراج ویژگی‌های کلیدی از تصاویر رانندگان، از شبکه پیش‌آمورخته MobileNetV2 به عنوان بدنه اصلی (Backbone) استفاده گردید. لایه‌های سر طبقه‌بندی‌کننده (Classification Head) جدیدی به انتهای این شبکه اضافه شدند. نمودار بلاکی ساختار دقیق لایه‌ها و جریان داده‌ها در شکل ۱.۵ نشان داده شده است.

### MobileNetV2 Architecture




شکل ۱.۵: نمودار بلوکی معماری شبکه پیشنهادی مبتنی بر MobileNetV2

همان‌طور که در شکل ۱.۵ مشخص است، تصاویر ورودی با ابعاد  $224 \times 224 \times 3$  وارد شبکه شده و پس از گذر از لایه‌های استخراج ویژگی، توسط لایه Global Average Pooling خلاصه می‌شوند. سپس دو لایه کامل متصل (Dense) به همراه لایه‌های Dropout (با نرخ‌های ۵.۰ و ۳.۰) و Batch Normalization جهت جلوگیری از بیش‌برازش قرار گرفته‌اند.

### ۳.۲.۵ معماری شبکه پیشنهادی مبتنی بر ResNet50

معماری دوم بر پایه شبکه عمیق ResNet50 طراحی شده است. ساختار لایه‌های افزوده شده کاملاً مشابه مدل قبل تنظیم گردید تا امکان مقایسه عادلانه فراهم شود. دیاگرام ساختار این شبکه در شکل ۲.۵ به تصویر کشیده شده است.

## ResNet50 Architecture



شکل ۲.۵: نمودار بلوکی معماری شبکه پیشنهادی مبتنی بر ResNet50 به همراه لایه پیش‌پردازش یکپارچه.

نکته حائز اهمیت در معماری شکل ۲.۵، ادغام مستقیم تابع پیش‌پردازش (preprocess\_input) در ورودی مدل است؛ بدین صورت که تصاویر نرمال‌شده در بازه  $[0, 1]$  پس از ورود به مدل، به صورت داخلی در عدد ۲۵۵ ضرب شده و آماده ورود به بلوک‌های باقی‌مانده (Residual Blocks) می‌گردند.

### ۳.۵ استراتژی آموزش دو فاز (Two-Phase\_Training\_Strategy)

برای دستیابی به بیشترین دقت اعتبارسنجی و همگرایی پایدار، فرآیند آموزش شبکه‌ها به دو فاز مجزا تقسیم شده است.



### ۱.۳.۵ فاز اول: استخراج ویژگی (Feature\_Extraction)

در این فاز، تمام لایه‌های بدنه اصلی شبکه (Backbone) منجمد (Frozen) می‌شوند. هدف اصلی این فاز، آموزش اولیه لایه‌های سفارشی جدید بدون دست‌کاری و تخریب وزن‌های ارزشمند پیش‌آموزش دیده ImageNet است.

- وضعیت لایه‌ها: Base Model Layers = Non-trainable
- پارامترهای قابل آموزش: فقط پارامترهای سر طبقه‌بندی سفارشی.
- نرخ یادگیری (Learning\_Rate): نرخ نسبتاً بالای  $\eta_1 = 10^{-3}$  جهت همگرایی سریع لایه‌های جدید.
- تعداد دوره‌ها (Epochs): آموزش به مدت ۱۰ تا ۱۵ دور اولیه.

### ۲.۳.۵ فاز دوم: تنظیم دقیق (Fine-Tuning)

پس از همگرایی اولیه سر طبقه‌بندی، قفل لایه‌های عمیق بدنه اصلی باز می‌شود (Unfrozen) تا لایه‌های فوقانی شبکه بتوانند ویژگی‌های بصری خود را متناسب با جزئیات خاص مجموعه داده State\_Farm (مانند وضعیت دقیق انگشتان یا زاویه دید داخل کابین) تطبیق دهند.

- وضعیت لایه‌ها در ResNet50: آزادسازی لایه‌های بلاک انتهایی شبکه (حدود ۳۰ لایه آخری) برای تنظیم دقیق.
- وضعیت لایه‌ها در MobileNetV2: آزادسازی لایه‌های فوقانی (از لایه ۱۰۰ به بعد).
- نرخ یادگیری (Learning\_Rate): استفاده از نرخ یادگیری بسیار کوچک  $\eta_2 = 10^{-5}$  جهت جلوگیری از تغییرات شدید و مخرب در وزن‌های پیش‌آموزش دیده.
- تعداد دوره‌ها (Epochs): ادامه آموزش به مدت ۱۵ تا ۲۰ دوره تکمیلی.

## ۴.۵ هاپیر پارامترها و مکانیزم‌های کنترلی آموزش

### ۱.۴.۵ تنظیمات هاپیر پارامترها

جدول ۲.۵ هاپیر پارامترهای کلیدی مورد استفاده در آموزش هر دو شبکه را نشان می‌دهد.

جدول ۲.۵: تنظیمات هاپیر پارامترهای آموزش شبکه‌ها

| هاپیر پارامتر               | مقدار در فاز ۱ (Feature_Extraction)       | مقدار در فاز ۲ (Fine-Tuning)              |
|-----------------------------|-------------------------------------------|-------------------------------------------|
| اندازه دسته (Batch Size)    | ۳۲                                        | ۳۲                                        |
| بهینه‌ساز (Optimizer)       | Adam ( $\beta_1 = 0.9, \beta_2 = 0.999$ ) | Adam ( $\beta_1 = 0.9, \beta_2 = 0.999$ ) |
| نرخ یادگیری (Learning Rate) | $1 \times 10^{-3}$                        | $1 \times 10^{-5}$                        |
| تابع زیان (Loss Function)   | Cross-Entropy Categorical                 | Cross-Entropy Categorical                 |
| معیار اصلی (Metric)         | Accuracy                                  | Accuracy                                  |



## ۲.۴.۵ کال‌بک‌ها و مکانیزم‌های کنترلی (Callbacks)

برای نظارت بر روند آموزش و جلوگیری از بیش‌برازش، از سه مکانیزم هوشمند استفاده گردید:

۱. کال‌بک 'ModelCheckpoint': ذخیره خودکار بهترین وزن‌های شبکه بر اساس کمترین میزان زیان اعتبارسنجی ( $val\_loss$ ).
۲. کال‌بک 'ReduceLROnPlateau': کاهش خودکار نرخ یادگیری با ضریب 0.2 در صورتی که زیان اعتبارسنجی به مدت ۳ دوره پیاپی بهبودی پیدا نکند ( $factor = 0.2, patience = 3$ ).
۳. کال‌بک 'EarlyStopping': متوقف کردن فرآیند آموزش در صورت عدم بهبود عملکرد اعتبارسنجی به مدت ۵ دوره پیاپی ( $patience = 5$ ) جهت جلوگیری از اتلاف منابع محاسباتی.

## ۵.۵ جمع‌بندی فصل

در این فصل معماری لایه‌های طبقه‌بندی سفارشی، دلایل استفاده از لایه‌های GAP و Dropout و استراتژی آموزش دوفازی ( $FeatureExtraction \& FineTuning$ ) به همراه هاپرپارامترها و مکانیزم‌های هوشمند کنترل نرخ یادگیری تشریح گردید. این پیکربندی‌های ساختاری و عملیاتی، زیرساخت کامل اجرای آزمایش‌ها و ثبت نتایج در فصل بعدی را فراهم ساخته‌اند.

## ۶ نتایج تجربی و ارزیابی عملکرد


### ۱.۶ مقدمه

پس از پیاده‌سازی معماری‌های پیشنهادی، تنظیم هایپرپارامترها و پیکربندی استراتژی آموزش دو فاز (شامل فاز استخراج ویژگی و تنظیم دقیق) در فصل پنجم، در این فصل نتایج حاصل از آموزش و ارزیابی دو مدل ResNet50 و MobileNetV2 روی مجموعه داده تشخیص حواس‌پرتی راننده به صورت کمی و کیفی مورد تحلیل و مقایسه قرار می‌گیرند.

### ۲.۶ نتایج ارزیابی مدل ResNet50

مدل ResNet50 به دلیل بهره‌گیری از بلوک‌های باقیمانده (Residual Blocks) توانست شیب گرادیان را به خوبی مدیریت کرده و ویژگی‌های بسیار عمیق و پیچیده‌ای را از تصاویر داخل کابین استخراج کند. این مدل پس از طی فاز دوم تنظیم دقیق، به همگرایی بسیار مطلوبی دست یافت.

- دقت نهایی روی مجموعه آزمون: 99.58%
- میانگین امتیاز F1: 0.995
- زمان آموزش هر دوره (Epoch): حدود ۱۲۰ ثانیه



شکل ۱.۶: منحنی‌های تغییرات دقت، زیان (Loss)، نرخ یادگیری (Learning\_Rate) و خلاصه شاخص‌های عملکردی مدل ResNet50 طی ۲ فاز آموزش.

روند آموزش شبکه عصبی عمیق ResNet50 در دو فاز مجزا (فاز اول با ۱۵ اپوک جهت آموزش لایه‌های فوقانی و فاز دوم با ۸ اپوک جهت تنظیم دقیق لایه‌های عمیق‌تر) صورت پذیرفت. شکل ۱.۶ تغییرات شاخص‌های ارزیابی را طی فرایند آموزش نشان می‌دهد.

با تحلیل نمودارهای شکل ۱.۶ نکات زیر قابل استنتاج است:


- روند دقت و زیان (Accuracy&Loss): در فاز اول آموزش، منحنی‌های دقت آموزش و اعتبارسنجی با شیب مناسبی صعودی بوده و میزان زیان (Loss) کاهش چشمگیری داشته است. با ورود به فاز دوم (Fine-Tuning) و آزادسازی لایه‌های عمیق‌تر، جهش محسوسی در دقت اعتبارسنجی مشاهده می‌شود که نشان‌دهنده تطبیق بهتر ویژگی‌های استخراج‌شده با دادگان آزمون است.
- عدم وقوع بیش‌برازش (Overfitting): فاصله اندک بین منحنی آموزش (خط آبی) و منحنی اعتبارسنجی (خط قرمز) اثبات می‌کند تکنیک‌های تنظیم‌سازی (Regularization) و افزایش داده (Data Augmentation) مانع از بیش‌برازش مدل شده‌اند.
- کاهش نرخ یادگیری (Learning\_Rate\_Scheduler): نمودار نرخ یادگیری منطبق بر استراتژی کاهش تدریجی تنظیم شده که به ثبت همگرایی پایدار در اپوک‌های پایانی کمک کرده است.

## ۱.۲.۶ تحلیل گام به گام آموزش و ارزیابی مدل ResNet50

در این بخش، روند آموزش مدل ResNet50 که در دو فاز مجزا اجرا شده است، به صورت تفکیکی و ترتیبی مورد تحلیل قرار می‌گیرد.

فاز اول: استخراج ویژگی‌ها (Feature\_Extraction)

در ۱۵ اپوک نخست، لایه‌های پایه‌ای شبکه منجمد شده و تنها بخش سر طبقه‌بندی‌کننده (Classification Head) آموزش داده شد. شکل ۲.۶ تغییرات شاخص‌های دقت، زیان و دقت Top-3 را در این فاز نشان می‌دهد.




شکل ۲.۶: منحنی‌های ارزیابی مدل ResNet50 در فاز اول آموزش (استخراج ویژگی‌ها - اپوک‌های ۱ تا ۱۵).

همان‌طور که در شکل ۲.۶ مشاهده می‌شود، میزان دقت اعتبارسنجی از ۹۴/۱۵٪ در اپوک اول سریعاً به ۹۹/۴۵٪ در اپوک ۱۰ می‌رسد که نشان‌دهنده توانایی بالای ویژگی‌های پیش‌آمोخته شبکه ResNet50 در بازنمایی رفتارهای راننده است.

فاز دوم: تنظیم دقیق (Fine-Tuning)

پس از تثبیت وزن‌های اولیه، لایه‌های عمیق‌تر شبکه آزاد شده و با نرخ یادگیری بسیار کوچک ( $10^{-5}$ ) طی ۸ اپوک مورد تنظیم دقیق قرار گرفتند (شکل ۳.۶).




شکل ۳.۶: منحنی‌های ارزیابی مدل ResNet50 در فاز دوم آموزش (تنظیم دقیق - اپوک‌های ۱۶ تا ۲۳).


با توجه به شکل ۳.۶، اعمال تنظیم دقیق منجر به کاهش نوسانات زیان اعتبارسنجی (Validation Loss) و بهبود همگرایی مدل در مرز کلاس‌های پیچیده شده است.

جمع‌بندی عملکرد و سیر تکاملی مدل

به منظور خلاصه نمودن عملکرد، شکل ۴.۶ بیشینه مقادیر به دست آمده در دو فاز را مقایسه کرده و شکل ۵.۶ سیر تکاملی یکپارچه شاخص‌ها را طی ۲۳ اپوک به تصویر می‌کشد.



شکل ۴.۶: مقایسه بیشینه شاخص‌های Accuracy و Accuracy Top-۳ مدل ResNet۵۰ در فازهای آموزش و اعتبارسنجی.



شکل ۵.۶: روند تکاملی یکپارچه دقت و دقت Top-۳ مدل ResNet۵۰ طی کل ۲۳ اپوک آموزش (ترکیب فاز ۱ و ۲).

طابق نمودار شکل ۵.۶، مدل در نهایت به **\*\*دقت اعتبارسنجی ۹۹/۵۴٪\*\*** و **\*\*دقت Top-۳ اعتبارسنجی ۹۹/۹۸٪\*\*** دست یافته است که نشان‌دهنده عملکرد فوق‌العاده پایداری مدل در تمامی ۱۰ کلاس رفتاری است.


## ۳.۶ نتایج ارزیابی مدل MobileNetV2

مدل MobileNetV2 با تکیه بر کانولشن‌های تفکیک‌پذیر عمقی (Depthwise Separable Convolutions) به عنوان یک مدل سبک‌وزن برای سیستم‌های بلادرنگ و لبه‌ای (Edge Devices) ارزیابی شد. این مدل با وجود کاهش چشمگیر تعداد پارامترها، دقت رقابتی و قابل توجهی را به نمایش گذاشت.

- دقت نهایی روی مجموعه آزمون: 94.42%
- میانگین امتیاز F1: 0.943
- زمان آموزش هر دوره (Epoch): حدود ۴۵ ثانیه

### ۱.۳.۶ نتایج ارزیابی مدل MobileNetV2


جهت ارزیابی عملکرد شبکه سبک MobileNetV2، روند تغییرات شاخص‌های دقت (Accuracy)، تابع زیان (Loss) و نرخ یادگیری (Learning Rate) طی ۲۳ اپوک آموزش (ترکیب ۱۵ اپوک فاز استخراج ویژگی و ۸ اپوک تنظیم دقیق) در شکل ۶.۶ ترسیم شده است.



شکل ۶.۶: منحنی‌های ارزیابی روند آموزش شبکه MobileNetV2 طی دو فاز استخراج ویژگی و تنظیم دقیق به همراه جدول خلاصه شاخص‌های عملکردی در بخش ۳.۶




همان طور که در نمودارهای شکل ۶.۶ مشاهده می شود، با اعمال نرخ یادگیری  $10^{-5}$  در فاز دوم (خط چین خاکستری)، روند همگرایی شبکه بدون بروز افت ناشی از تخریب وزن ها ادامه یافته و دقت اعتبارسنجی به میزان مطلوب تثبیت شده است.




شکل ۷.۶: منحنی های دقت، زیان و دقت Top-۳ مدل MobileNetV۲ در فاز اول آموزش (استخراج ویژگی طی ۱۵ اپوک)

در فاز اول آموزش شبکه MobileNetV۲ (شکل ۷.۶)، وزن های بدنه اصلی شبکه انجاماد یافته و تنها لایه های سر طبقه بندی سفارشی آموزش دیدند. همان طور که در نمودار مشاهده می شود، دقت اعتبارسنجی از ۷۶/۰۳٪ در اپوک اول به ۸۹/۷۶٪ در اپوک ۱۵ رسید. نکته قابل توجه بالاتر بودن دقت اعتبارسنجی نسبت به دقت آموزش در اپوک های اولیه است که ناشی از اعمال تکنیک های شدید افزایش داده (Data Augmentation) بر روی داده های آموزش و استفاده از لایه های Dropout می باشد. شاخص Top-3 Accuracy نیز در انتهای این فاز به ۹۸/۰۴٪ تثبیت گردید که نشان دهنده قدرت بالای وزن های پیش آموخته ImageNet در استخراج ویژگی های بصری اولیه است.




شکل ۸.۶: منحنی های ارزیابی عملکرد MobileNetV۲ در فاز دوم (تنظیم دقیق / Fine-Tuning طی ۸ اپوک)

پس از خروج لایه های انتهایی از حالت انجاماد و کاهش نرخ یادگیری به  $10^{-5}$ ، روند آموزش در فاز دوم ادامه یافت (شکل ۸.۶). در این فاز، دقت اعتبارسنجی با طی یک روند صعودی یکنواخت و بدون نوسان مخرب، از ۸۶/۷۰٪ به ۹۴/۴۲٪ افزایش یافت و تابع زیان اعتبارسنجی تا مقدار ۰/۲۸۷۷ افت کرد. نرخ Top-3 Accuracy نیز به عدد ۹۹/۳۸٪ دست یافت. افت مداوم تابع زیان در هر دو مجموعه آموزش و اعتبارسنجی اثبات می کند که نرخ یادگیری کوچک اتخاذ شده مانع از پدیده تخریب وزن ها (Weight Catastrophic Forgetting) شده است.



شکل ۹.۶: روند تکاملی یکپارچه شاخص‌های Accuracy و Top-3\_Accuracy مدل MobileNetV2 طی کل ۲۳ اپوک آموزش

شکل ۹.۶ نمایی پیوسته از ۲۳ اپوک آموزش شبکه را نمایش می‌دهد. خط‌چین خاکستری در اپوک ۱۵ مرز میان دو فاز استخراج ویژگی و تنظیم دقیق را مشخص می‌کند. تغییر شیب منحنی‌ها پس از خط‌چین به‌وضوح تأثیر مثبت آزادسازی لایه‌های عمیق را در بازشناسی الگوهای پیچیده رفتاری راننده نشان می‌دهد. عدم وجود فاصله زیاد میان منحنی‌های آموزش (آبی/سبز) و اعتبارسنجی (قرمز/ارغوانی) گواهی بر سلامت فرایند آموزش و عدم بروز بیش‌برازش (Overfitting) است.



شکل ۱۰.۶: مقایسه میله‌ای بالاترین دقت‌های به‌دست‌آمده (Top-1&Top-3) در مجموعه‌های آموزش و اعتبارسنجی طی فازهای ۱ و ۲ مدل MobileNetV2


جهت تحلیل دقیق‌تر جهش عملکردی مدل، مقادیر اوج شاخص‌های دقت در شکل ۱۰.۶ مقایسه شده‌اند. تنظیم دقیق لایه‌ها در فاز دوم موجب ارتقای دقت اعتبارسنجی از ۸۹/۷۶٪ به ۹۴/۴۲٪ (رشد ۴/۶۶ درصدی) شده است. همچنین خط آستانه ۹۵٪ (خط‌چین سبز) نشان می‌دهد که معیار Top-3 Accuracy در هر دو فاز به‌راحتی از این حد نصاب عبور کرده و در فاز دوم به ۹۹/۳۸٪ رسیده است؛ امری که نشان می‌دهد پاسخ صحیح مدل تقریباً همواره در میان ۳ پیش‌بینی اول با اطمینان بالا

قرار دارد.

## ۴.۶ ماتریس درهم‌ریختگی و تحلیل خطاها

بررسی ماتریس درهم‌ریختگی (Confusion Matrix) نشان می‌دهد که بیشترین میزان خطای دسته‌بندی در هر دو مدل مربوط به کلاس‌های مشابه رفتاری، نظیر «تنظیم رادیو» و «برداشتن چیزی از داشبورد» یا «صحبت کردن با مسافر» بوده است؛ زیرا زاویه قرارگیری دستان راننده و الگوی پوششی تصویر در این کلاس‌ها همپوشانی بالایی دارد. با این حال، به لطف استفاده از لایه‌های Dropout و استراتژی دو فازی، خطاهای انحرافی به حداقل ممکن رسیده‌اند.

### ۱.۴.۶ تحلیل ماتریس درهم‌ریختگی مدل MobileNetV۲




شکل ۱۱.۶: ماتریس درهم‌ریختگی (Confusion Matrix) مدل بر روی داده‌های اعتبارسنجی برای ۱۰ کلاس رفتاری راننده

جهت بررسی دقیق عملکرد مدل در تفکیک کلاس‌های ده‌گانه و شناسایی نقاط ضعف در تشخیص رفتارهای خاص، ماتریس درهم‌ریختگی (Confusion Matrix) بر روی داده‌های اعتبارسنجی محاسبه و در شکل ۱۱.۶ رسم شده است.

همان‌طور که در قطر اصلی ماتریس شکل ۱۱.۶ مشاهده می‌شود، اکثر نمونه‌های مربوط به هر کلاس به درستی طبقه‌بندی شده‌اند. بیشترین دقت بازنمایی مربوط به کلاس‌های با الگوی دیداری متمایز مانند رانندگی عادی (c0: Normal driving) و صحبت با سرنشین (c9: Talking to passenger) است.

با این حال، تحلیل خطاهای متقاطع نشان می‌دهد که بیشترین سردرگمی مدل میان کلاس‌های متناظر دست چپ و دست راست رخ داده است؛ به‌ویژه میان کلاس‌های ارسال پیامک با دست راست (c1) و ارسال پیامک با دست چپ (c3)، و همچنین مکالمه با تلفن همراه با دست راست (c2) و دست چپ (c4). این خطای جزئی ناشی از شباهت بالای ساختار دیداری و موقعیت دست‌ها نسبت به فرمان خودرو است که در فصل هفتم به عنوان یکی از چالش‌های اصلی سیستم تحلیل شده است.

## ۲.۴.۶ تحلیل منحنی‌های ROC و شاخص AUC مدل MobileNetV۲



شکل ۱۲.۶: منحنی‌های ROC و مقادیر سطح زیر منحنی (AUC) به تفکیک ۱۰ کلاس رفتاری بر اساس رویکرد One-vs-Rest

ارزیابی توان تفکیک‌پذیری مدل بر اساس منحنی‌های ویژگی عملکردی گیرنده (ROC) و شاخص سطح زیر منحنی (AUC) بر پایه رویکرد یک‌در-برابر-همه (One-vs-Rest) در شکل ۱۲.۶ به تصویر کشیده شده است.

مقدار شاخص میانگین کل Macro-AUC برابر با +0.99 به دست آمده است که نشان‌دهنده حساسیت و ویژگی بسیار بالای مدل در تفکیک تمامی کلاس‌هاست. نزدیکی منحنی تمامی ۱۰ کلاس به گوشه بالا-چپ نمودار اثبات می‌کند که مدل حتی در آستانه‌های تصمیم‌گیری سخت‌گیرانه نیز نرخ مثبت واقعی (True Positive Rate) بالایی را حفظ کرده و نرخ مثبت کاذب


(False Positive Rate) بسیار ناچیزی دارد.

جدول ۱۰۶: جدول ارزیابی دقیق شاخص های، Recall Precision و F1-Score به تفکیک کلاس ها

| F1-Score | Recall | Precision | کلاس رفتاری               |
|----------|--------|-----------|---------------------------|
| ۰/۹۶     | ۰/۹۷   | ۰/۹۶      | c۰:Normal_driving         |
| ۰/۹۱     | ۰/۹۱   | ۰/۹۲      | c۱:Texting-right          |
| ۰/۹۴     | ۰/۹۵   | ۰/۹۴      | c۲:Talking_on_phone-right |
| ۰/۹۱     | ۰/۹۲   | ۰/۹۱      | c۳:Texting-left           |
| ۰/۹۴     | ۰/۹۴   | ۰/۹۵      | c۴:Talking_on_phone-left  |
| ۰/۹۶     | ۰/۹۶   | ۰/۹۶      | c۵:Operating_radio        |
| ۰/۹۵     | ۰/۹۵   | ۰/۹۵      | c۶:Drinking               |
| ۰/۹۶     | ۰/۹۶   | ۰/۹۷      | c۷:Reaching_behind        |
| ۰/۹۴     | ۰/۹۵   | ۰/۹۴      | c۸:Hair_and_makeup        |
| ۰/۹۷     | ۰/۹۷   | ۰/۹۷      | c۹:Talking_to_passenger   |
| ۰/۹۵     | ۰/۹۵   | ۰/۹۵      | Macro_Avg                 |
| ۰/۹۵     | ۰/۹۵   | ۰/۹۵      | Weighted_Avg              |

### ۳.۴.۶ تحلیل ماتریس درهم ریختگی مدل ResNet5۰

به منظور ارزیابی دقیق نحوه طبقه بندی و شناسایی خطاهای تفکیکی مدل ResNet50 بر روی داده های اعتبارسنجی، ماتریس درهم ریختگی (Confusion Matrix) در شکل ۱۳.۶ رسم شده است. قطر اصلی این ماتریس نشان دهنده تعداد نمونه های کاملاً درست طبقه بندی شده در هر یک از ۱۰ کلاس رفتاری است.




شکل ۱۳.۶: ماتریس درهم‌ریختگی مدل ResNet50 بر روی داده‌های اعتبارسنجی.

تحلیل ماتریس درهم‌ریختگی شکل ۱۳.۶ نتایج زیر را روشن می‌سازد:

- کلاسیفیکیشن برتر: اکثر عناصر غیرقطری صفر یا بسیار نزدیک به صفر هستند که تمرکز بالای قطری و دقت فوق‌العاده شبکه در تفکیک رفتارهای رانندگی را تایید می‌کند.
- تحلیل خطا در کلاس‌های مشابه: بیشترین خطای جزئی شبکه بین کلاس‌های Texting - right و Talking on phone - right رخ داده است که به دلیل شباهت بالایی دیداری در موقعیت دست و سر راننده کاملاً طبیعی و متداول است.

#### ۴.۴.۶ تحلیل منحنی‌های ROC و شاخص AUC مدل ResNet50

جهت ارزیابی نرخ مثبت واقعی (True Positive Rate) در برابر نرخ مثبت کاذب (False Positive Rate) برای هر کلاس، منحنی‌های ROC به صورت یک-در-برابر-همه (One-vs-Rest) در شکل ۱۴.۶ ترسیم شده‌اند.



شکل ۱۴.۶: منحنی‌های ROC و شاخص AUC مربوط به ۱۰ کلاس رفتاری راننده برای مدل ResNet50.

طابق شکل ۱۴.۶:

- مقدار شاخص Macro AUC برابر با ۱ به دست آمده است که نشان‌دهنده توانایی استثنایی مدل در تفکیک تمامی کلاس‌ها از یکدیگر است.
- چسبیدن تمامی منحنی‌ها به گوشه سمت چپ بالایی نمودار، مرز تصمیم‌گیری قدرتمند استخراج‌شده توسط ویژگی‌های ResNet50 را اثبات می‌کند.

## ۵.۶ مقایسه جامع عملکرد مدل‌ها

برای ارزیابی دقیق‌تر، شاخص‌های کلیدی عملکردی شامل صحت (Accuracy)، دقت (Precision)، یادآوری (Recall)، امتیاز F1-Score، تعداد پارامترهای قابل آموزش و زمان استنتاج در جدول ۲.۶ مقایسه شده‌اند.

جدول ۲.۶: مقایسه جامع معیارهای ارزیابی مدل‌های ResNet50 و MobileNetV2

| مدل         | دقت (%) | صحت   | یادآوری | امتیاز F1 | تعداد پارامترها |
|-------------|---------|-------|---------|-----------|-----------------|
| ResNet50    | ۹۹/۵۸   | ۰/۹۹۶ | ۰/۹۹۵   | ۰/۹۹۵     | ۲۵/۶ Million    |
| MobileNetV2 | ۹۴/۴۲   | ۰/۹۴۵ | ۰/۹۴۲   | ۰/۹۴۳     | ۳/۵ Million     |

همان‌طور که در جدول مشاهده می‌شود، مدل ResNet50 از نظر دقت عملکرد بالاتری دارد، در حالی که مدل MobileNetV2 با داشتن حجمی نزدیک به یک هفتم مدل اول، گزینه‌ای بهینه برای پیاده‌سازی بر روی سخت‌افزارهای محدود با قابلیت پردازش بلادرنگ محسوب می‌شود.

### ۱.۵.۶ مقایسه کیفی پیش‌بینی‌های ResNet50 و MobileNetV2 روی داده‌های آزمون

به منظور مقایسه دیداری و سنجش میزان همگرایی تصمیم‌گیری دو معماری ResNet50 و MobileNetV2، هر دو مدل بر روی ۱۰ تصویر یکسان از مجموعه آزمون (Test Set) اجرا شدند. شکل ۱۵.۶ خروجی پیش‌بینی و درصد اطمینان هر دو مدل را به صورت شانه به شانه نشان می‌دهد.



شکل ۱۵.۶: مقایسه کیفی هم‌زمان پیش‌بینی‌های دو مدل ResNet50 و MobileNetV2 روی ۱۰ نمونه تصادفی از داده‌های آزمون.


تحلیل مقایسه‌ای شکل ۱۵.۶ نکات زیر را آشکار می‌سازد:

- همگرایی در کلاس‌های قطعی: در اکثر تصاویر، هر دو مدل بر روی کلاس رفتاری یکسان توافق دارند و هر دو با درصد اطمینان بسیار بالا (غالباً بالای ۹۵٪) خروجی داده‌اند که نشان‌دهنده استخراج ویژگی‌های معتبر توسط هر دو شبکه است.
- تفاوت در درصد اطمینان (Confidence\_Level): مدل ResNet50 به دلیل ظرفیت پارامتری بالاتر، در تصاویر پیچیده‌تر با اطمینان کمی بالاتر عمل کرده است؛ در حالی که MobileNetV2 با وجود حجم بسیار کمتر پارامترها، نتایجی بسیار نزدیک و قابل رقابت با ResNet50 ارائه می‌دهد.

- پایداری در لایه‌های لبه (Edge\_Cases): هر دو مدل در تمایز دادن جهت‌های چپ و راست برای رفتارهای مشابه (مانند صحبت با تلفن با دست چپ در برابر دست راست) ثبات تصمیم‌گیری کاملی از خود نشان داده‌اند.

## ۲.۵.۶ مقایسه روند همگرایی و منحنی‌های دقت (Accuracy\_Curves)

به منظور بررسی رفتار یادگیری، سرعت همگرایی و میزان پایداری مدل‌ها طی ۲۳ اپوک آموزش (۱۵ اپوک فاز اول و ۸ اپوک فاز تنظیم جزیی)، منحنی‌های دقت آموزش (Train Accuracy) و اعتبارسنجی (Validation Accuracy) برای هر دو مدل ResNet50 و MobileNetV2 در شکل ۱۶.۶ ترسیم شده است.



شکل ۱۶.۶: مقایسه منحنی‌های دقت آموزش و اعتبارسنجی دو مدل ResNet50 و MobileNetV2 طی ۲۳ اپوک.

تحلیل روند منحنی‌های شکل ۱۶.۶ نکات زیر را نشان می‌دهد:

- برتری ResNet50 در سرعت همگرایی: مدل ResNet50 از ابتدای آموزش (فاز ۱) به دقت بالای ۹۰٪ دست یافته و منحنی اعتبارسنجی آن بسیار سریع به محدوده ۹۹/۵٪ رسیده است.
- تاثیر مثبت فاز دوم (Fine-tuning): تفکیک فاز آموزش در اپوک ۱۵ به خوبی نشان می‌دهد که اعمال تنظیم جزیی بر روی لایه‌های عمیق‌تر، موجب جهش دقت در مدل MobileNetV2 از حدود ۸۹٪ به بالای ۹۴/۴٪ شده است.
- عدم وجود بیش‌برازش (Overfitting): انطباق بالای منحنی‌های آموزش و اعتبارسنجی در هر دو مدل (و حتی بالاتر بودن دقت اعتبارسنجی در برخی اپوک‌ها به دلیل لایه‌های Dropout) عدم وقوع بیش‌برازش را تایید می‌کند.

## ۶.۶ نمونه خروجی‌های کیفی و استنتاج روی داده‌های آزمون

به منظور ارزیابی عملی و دیداری عملکرد مدل نهایی MobileNetV2، فرایند استنتاج (Inference) بر روی نمونه‌های تصادفی از داده‌های آزمون (Test Set) که در طول مراحل آموزش و اعتبارسنجی توسط شبکه دیده نشده بودند، انجام شد. هدف از این ارزیابی کیفی، سنجش میزان اطمینان مدل (Confidence Score) در پیش‌بینی رفتارهای مختلف راننده در شرایط واقعی است.

شکل ۱۷.۶ خروجی پیش‌بینی مدل را برای ۱۰ نمونه تصویری تصادفی نشان می‌دهد. در این تصویر، برچسب پیش‌بینی شده به همراه درصد اطمینان خروجی لایه Softmax در بالای هر تصویر درج شده است.

MobileNetV2 predictions on 10 random test images



شکل ۱۷.۶: نمونه پیش‌بینی‌های کیفی مدل MobileNetV2 روی ۱۰ تصویر تصادفی از داده‌های آزمون به همراه درصد اطمینان

همان‌طور که در شکل ۱۷.۶ مشاهده می‌شود:

- پیش‌بینی‌های با اطمینان بالا (رنگ سبز): در اکثر کلاس‌ها مانند «رانندگی عادی»، «صحبت با تلفن همراه» و «تنظیم رادیو»، مدل با میزان اطمینان بالای ۹۰٪ کلاس صحیح را تشخیص داده است.
- پیش‌بینی‌های با اطمینان متوسط (رنگ نارنجی): در شرایطی که زوایای دید یا حالت دست راننده مبهم‌تر است، میزان اطمینان بین ۷۰٪ تا ۹۰٪ قرار گرفته که نشان‌دهنده کالیبراسیون مناسب خروجی‌های احتمالات شبکه است.
- تشخیص دست چپ و راست: مدل در تمایز دادن رفتارهای مشابه (مانند ارسال پیامک با دست چپ در برابر دست راست) توانایی دیداری بالایی از خود نشان داده است.

ارزیابی کیفی پیش‌بینی‌های مدل ResNet50 روی داده‌های آزمون

به منظور ارزیابی عملی عملکرد مدل ResNet50 بر روی داده‌های کاملاً جدید، تعداد ۱۰ تصویر به صورت تصادفی از مجموعه آزمون (Test Set) انتخاب شده و پیش‌پردازش بازه [0, 1] بر روی آن‌ها اعمال گردید. خروجی استنتاج مدل به همراه درصد اطمینان خروجی لایه Softmax در شکل ۱۸.۶ نشان داده شده است.



ResNet50 - Correct predictions (normal 0-1 input)



شکل ۱۸.۶: پیش‌بینی‌های کیفی مدل ResNet50 روی ۱۰ نمونه تصادفی از داده‌های آزمون به همراه درصد اطمینان.

همان‌طور که در شکل ۱۸.۶ ملاحظه می‌شود:

- اعمال نرمال‌سازی دقیق ورودی در بازه  $[0, 1]$  موجب ثبات پیش‌بینی‌ها شده و مدل در اکثر کلاس‌ها به درصد اطمینان بالای ۹۰٪ (مشخص‌شده با رنگ سبز) دست یافته است.
- شبکه ResNet50 با استخراج ویژگی‌های عمیق‌تر، توانسته است حالات پیچیده‌تر نظیر «ارسال پیامک» یا «صحبت با تلفن» با دست چپ و راست را به درستی تفکیک کند.

## ۷.۶ جمع‌بندی فصل

در این فصل، نتایج پیاده‌سازی و اجرای دو شبکه عمیق ResNet50 و MobileNetV2 ارزیابی شد. مقایسه کمی نشان داد که مدل ResNet50 بالاترین دقت تشخیصی (99.58%) را ارائه می‌دهد و مدل MobileNetV2 تعادل عالی میان سرعت پردازش و دقت (94.42%) برقرار می‌کند. در فصل آینده، نتیجه‌گیری کلی پژوهش و پیشنهادات برای پژوهش‌های آتی ارائه خواهد گردید.

## ۷ چالش‌های فنی، موانع اجرایی و راهکارهای مواجهه

### ۱.۷ مقدمه

پیاده‌سازی سامانه‌های هوشمند مبتنی بر بینایی ماشین برای محیط‌های حساس و متغیری نظیر داخل کابین خودرو، همواره با چالش‌های متعدد فنی، داده‌ای و محاسباتی همراه است. اگرچه مدل‌های عمیق توانایی بالایی در استخراج ویژگی‌ها دارند، اما مواجهه با شرایط واقعی چالش‌های ویژه‌ای را فراروی فرآیند آموزش قرار می‌دهد. در این فصل، چالش‌های کلیدی مواجهه‌شده در طول مراحل مختلف این پژوهش (از پیش‌پردازش داده‌ها تا فاز تنظیم دقیق شبکه‌ها) به همراه راهکارهای عملی اتخاذشده برای غلبه بر آن‌ها به تفصیل تشریح می‌شوند.

### ۲.۷ چالش اول: شباهت بالای بین کلاسی و همپوشانی رفتاری (High\_Inter\_class\_Similarity)

یکی از پیچیده‌ترین چالش‌های این پروژه، شباهت بصری بسیار نزدیک بین برخی از کلاس‌های ۱۰ گانه رفتار راننده بود.

#### ۱.۲.۷ تحلیل ابعاد چالش

تصاویر مربوط به کلاس‌هایی مانند  $c_1$  (تایپ با دست راست) و  $c_3$  (مکالمه تلفنی با دست راست) یا کلاس‌های  $c_2$  (تایپ با دست چپ) و  $c_4$  (مکالمه با دست چپ) از نظر موقعیت کلی بدن، ساختار چهره و زاویه قرارگیری دست‌ها همپوشانی فوق‌العاده بالایی دارند. در بسیاری از فریم‌ها، تنها تفاوت موجود، جابه‌جایی چند سانتی‌متری گوشی تلفن همراه نسبت به گوش یا چانه راننده بود.

#### ۲.۲.۷ راهکار اتخاذشده

- برای غلبه بر این تشابه شدیدی که موجب سردرگمی شبکه‌های معمولی می‌شد، دو استراتژی مکمل به کار گرفته شد:
- طراحی در طبقه‌بندی عمیق با لایه‌های میانجی dense: اضافه کردن لایه ۵۱۲ و ۲۵۶ نرونی با تابع فعال‌سازی  $ReLU$  به مدل اجازه‌داد تا نگاشت‌های ویژگی غیرخطی و پیچیده‌تری را از خروجی‌های بدنه اصلی استخراج کند.
  - افزایش نرخ تفکیک مکانی ورودی: ابعاد ورودی تصاویر در محدوده  $224 \times 224$  پیکسل با تکنیک‌های بازنمایی جزئیات ریز لبه‌ها تنظیم شد تا شبکه بتواند اشیاء کوچکی نظیر تلفن همراه را در مجاورت گوش یا دست راننده تفکیک کند.

### ۳.۷ چالش دوم: چالش بیش‌برازش (Overfitting) و عدم تعادل داده‌ها

تصاویر داخل کابین به دلیل ثابت بودن زاویه دوربین، زمینه پس‌زمینه (صندلی و کابین) یکسانی دارند. این تشابه پس‌زمینه باعث می‌شود شبکه‌های عمیق به جای یادگیری «رفتار راننده»، ویژگی‌های «پس‌زمینه خودرو» را حفظ کنند و دچار بیش‌برازش

شدید گردند.

### ۱.۳.۷ تحلیل ابعاد چالش

در آزمایش‌های اولیه با شبکه ResNet50 بدون مکانیزم‌های تنظیم‌کننده (Regularization)، دقت شبکه روی داده‌های آموزش به سرعت به ۱۰٪ می‌رسید اما روی داده‌های اعتبارسنجی افت شدیدی (زیر ۸۰٪) را نشان می‌داد که نشان‌دهنده حفظ کردن تصاویر آموزش بود.

### ۲.۳.۷ راهکار اتخاذشده

- اعمال لایه‌های Dropout دوگانه: قرار دادن لایه‌های Dropout با نرخ‌های 0.5 و 0.3 به عنوان سدی در برابر وابستگی شبکه به نورون‌های خاص عمل کرد.
- استفاده از الگوریتم‌های پیشرفته افزودن داده (Data\_Augmentation): تغییرات تصادفی شامل چرخش‌های کوچک ( $\pm 10^\circ$ )، برش‌های افقی و عمودی (Zoom/Shift) و تغییرات کنترل‌شده روشنی تصویر به مدل آموزش داد تا به پس‌زمینه ثابت وابسته نباشد.

## ۴.۷ چالش سوم: فرار گرادیان و تخریب وزن‌ها در فاز Fine-Tuning

در فرآیند یادگیری انتقالی، اگر قفل لایه‌های اصلی شبکه (Backbone) بدون برنامه‌ریزی باز شود، نرخ‌های یادگیری بزرگ می‌توانند وزن‌های پیش‌آموزش دیده ارزشمند روی داده‌های ImageNet را به شدت تخریب کنند که به اصطلاح *Catastrophic Forgetting* نامیده می‌شود.

### ۱.۴.۷ تحلیل ابعاد چالش

در شروع فاز تنظیم دقیق، لایه‌های اولیه و میانی شبکه که استخراج‌کننده ویژگی‌های عمومی (مانند لبه‌ها و بافت‌ها) هستند، در صورت مواجهه با گرادیان‌های بزرگ دستخوش تغییرات شدید شده و عملکرد کلی مدل سقوط می‌کند.

### ۲.۴.۷ راهکار اتخاذشده

۱. استراتژی آموزش دو فازی مجزا (Two\_Phase\_Training): ابتدا کل بدنه شبکه منجمد شد تا فقط طبقه‌بندی سفارشی آموزش ببیند.
۲. افت شدید نرخ یادگیری (Learning Rate Decay): در فاز دوم تنها لایه‌های عمیق پایانی آزادسازی شدند و نرخ یادگیری از  $\eta = 10^{-3}$  به نرخ بسیار کوچک  $\eta = 10^{-5}$  کاهش یافت.
۳. به‌کارگیری کالک‌بک هوشمند (ReduceLROnPlateau): کاهش خودکار نرخ یادگیری در صورت درج‌آوردن میزان زیان اعتبارسنجی.

## ۵.۷ چالش چهارم: شرایط نوری پیچیده، نور شدید مستقیم و سایه‌های کابین

یکی از مهم‌ترین و عملیاتی‌ترین چالش‌های بصری در پردازش تصاویر داخل خودرو، عدم ثبات شرایط نوری، تابش مستقیم نور خورشید و ایجاد سایه‌های شدید و متحرک است.

### ۱.۵.۷ تحلیل ابعاد چالش

در شرایط رانندگی روزانه، تغییر زاویه خودرو نسبت به خورشید باعث ورود ناگهانی نور شدید (Glare/Overexposure) یا ایجاد سایه‌های تیره‌رنگ روی چهره، دستان و فرمان خودرو می‌شود. این پدیده باعث دو مشکل عمده می‌گردد:

۱. اشباع نوری و از دست رفتن بافت: ورود نور مستقیم باعث سفید شدن بخش‌هایی از تصویر و نابودی ویژگی‌های بافت (Texture) می‌شود.

۲. ایجاد کنتراست شدید و لبه‌های کاذب: سایه‌های تیز روی بدن راننده، لبه‌های مصنوعی ایجاد می‌کنند که توسط لایه‌های اولیه شبکه به اشتباه به عنوان لبه‌های اشیاء (نظیر گوشی یا دست) تفسیر می‌شوند.

### ۲.۵.۷ راهکار اتخاذشده

برای کاهش حساسیت شبکه به تغییرات شدید نوری و سایه‌ها، اقدامات زیر در مرحله پیش‌پردازش و افزوده داده انجام پذیرفت:

- اعمال تکنیک تعدیل هموار بافت (Histogram\_Equalization): استفاده از پیش‌پردازش‌های کنتراست پویا جهت تعدیل توزیع روشنایی در بخش‌های تاریک و روشن تصویر.

- افزودن داده مبتنی بر تغییرات روشنایی و کنتراست (Random\_Brightness&Contrast): اعمال تغییرات تصادفی شدت نور و کنتراست در بازه  $[-20\%, +20\%]$  در طول آموزش فاز اول، تا مدل یاد بگیرد ویژگی‌های ساختاری مستقل از شدت نور را استخراج کند.

## ۶.۷ جمع‌بندی فصل

در این فصل، چالش‌های اصلی مسیر توسعه سیستم هوشمند تشخیص حواس‌پرتی راننده تشریح گردید. غلبه بر چالش‌های شباهت بین‌کلاسی، بیش‌برازش، تخریب وزن‌ها و محدودیت‌های سخت‌افزاری از طریق اتخاذ استراتژی‌های هوشمندانه‌ای نظیر آموزش دو فاز، تنظیم نرخ‌های یادگیری تفکیک‌شده، اعمال لایه‌های Dropout و استفاده از مدل‌های سبک‌وزن محقق شد که زیربنای اصلی دستیابی به دقت‌های بالای گزارش‌شده در فصل‌های قبلی بود.

## ۸ نتیجه‌گیری، دستاوردها و پیشنهادات برای پژوهش‌های آتی

### ۱.۸ مقدمه

حواس‌پرتی راننده یکی از عوامل اصلی حوادث جاده‌ای و تصادفات مرگبار در سطح جهان است. با گسترش روزافزون فناوری‌های خودکارسازی و سیستم‌های پیشرفته دستیار راننده (ADAS)، طراحی سامانه‌های هوشمند بینایی ماشین جهت پایش رفتار راننده داخل کابین به یکی از محورهای اصلی پژوهش‌های صنعتی و دانشگاهی تبدیل شده است. در این پروژه، یک خط‌لوله (Pipeline) کامل مبتنی بر یادگیری عمیق و یادگیری انتقالی (Transfer Learning) برای طبقه‌بندی ۱۰ حالت رفتاری راننده بر روی مجموعه داده استاندارد State Farm طراحی و پیاده‌سازی گردید. در این فصل، جمع‌بندی جامعی از کلیه مراحل انجام‌شده، دستاوردهای کلیدی و پیشنهادات آتی ارائه می‌شود.

### ۲.۸ خلاصه پژوهش و دستاوردهای کلیدی

- در طول این پژوهش، دو معماری عمیق با ویژگی‌های ساختاری متفاوت مورد ارزیابی، پیاده‌سازی و مقایسه قرار گرفتند:
۱. معماری ResNet۵۰: به عنوان نماینده مدل‌های بسیار عمیق مبتنی بر اتصالات باقیمانده (Residual Connections).
  ۲. معماری MobileNetV۲: به عنوان نماینده مدل‌های سبک‌وزن و بهینه‌شده برای پردازش‌های بلادرنگ مبتنی بر کانولوشن‌های تفکیک‌پذیر عمقی (Depthwise Separable Convolutions).
- برای دستیابی به بیشترین دقت و پایداری در آموزش، لایه‌های پایانی شبکه‌ها حذف و با یک سر طبقه‌بندی سفارشی (Custom Head) جایگزین شدند. همچنین استراتژی آموزش دو فاز (شامل فاز استخراج ویژگی و فاز تنظیم دقیق) به همراه تنظیم دقیق نرخ یادگیری به کار گرفته شد.

#### ۱.۲.۸ خلاصه نتایج کمی

جدول ۱.۸ خلاصه عملکرد نهایی مدل‌های پیاده‌سازی‌شده بر روی داده‌های آزمون را نشان می‌دهد.

جدول ۱.۸: جمع‌بندی عملکرد مدل‌های پیاده‌سازی‌شده در پژوهش

| مدل         | دقت (%) | صحت   | یادآوری | امتیاز F1 | تعداد پارامترها |
|-------------|---------|-------|---------|-----------|-----------------|
| ResNet۵۰    | ۹۹/۵۸   | ۰/۹۹۶ | ۰/۹۹۵   | ۰/۹۹۵     | ۲۵/۶M           |
| MobileNetV۲ | ۹۴/۴۲   | ۰/۹۴۵ | ۰/۹۴۲   | ۰/۹۴۳     | ۳/۵M            |

همان‌طور که نتایج نشان می‌دهند:

- مدل ResNet۵۰ توانست به دقت فوق‌العاده ۹۹/۵۸٪ دست یابد. این مدل با بهره‌گیری از عمق بالا، توانایی بالایی در تفکیک حالات رفتاری بسیار مشابه (نظیر صحبت با تلفن در برابر تایپ کردن) نشان داد.



- مدل MobileNetV۲ با داشتن تنها حدود ۳/۵ میلیون پارامتر (حدود یک‌هفتم حجم ResNet50) و کاهش زمان آموزش و استنتاج به یک‌سوم، دقت بسیار خوب ۹۴/۴۲٪ را ثبت کرد.

### ۳.۸ بحث و موازنه دقت و کارایی محاسباتی (Trade\_off\_Analysis)

- یکی از مهم‌ترین برآوردهای این پژوهش، تحلیل موازنه میان «دقت تشخیصی» و «پیچیدگی محاسباتی» است:
- اگر هدف سیستم، حداکثر دقت ممکن در سامانه ثبت اطلاعات خودرو باشد یا محدودیت سخت‌افزاری وجود نداشته باشد، مدل ResNet۵۰ گزینه برتر است.
  - اما اگر هدف، پیاده‌سازی سامانه روی بردهای سخت‌افزاری لبه‌ای (Edge Devices) با منابع محدود (مانند Raspberry Pi یا Jetson Nano) برای پردازش بلادرنگ (Real-time) باشد، مدل MobileNetV۲ به دلیل مصرف پایین حافظه و سرعت استنتاج بالا، تعادل بی‌نظیری میان سرعت و دقت ارائه می‌دهد.

### ۴.۸ پیشنهادات برای پژوهش‌های آتی

- جهت ارتقا و توسعه بیشتر سامانه‌های هوشمند تشخیص حواس‌پرتی راننده، مسیرهای پژوهشی زیر پیشنهاد می‌گردد:
۱. به‌کارگیری شبکه‌های ترکیبی فضایی-زمانی ( $CNN+LSTM/VisionTransformers$ ): تحلیل تک‌تصاویر استاتیک ممکن است در حالات مرزی با خطا همراه باشد. استفاده از مدل‌های سری زمانی مانند LSTM یا Video Transformers روی دنباله فریم‌های ویدئویی به سیستم اجازه می‌دهد تا بعد «زمان» را نیز در تشخیص رفتار وارد کند.
  ۲. فشرده‌سازی و کوانتیزاسیون مدل‌ها (Quantization&Pruning): اعمال تکنیک‌های هرس شبکه و کوانتیزاسیون ۸-بیتی (INT8) روی مدل ResNet50 جهت کاهش حجم و افزایش سرعت استنتاج آن بدون افت محسوس دقت.
  ۳. ادغام داده‌های چندسنسوره (Multi-Sensor Fusion): ترکیب داده‌های بصری دوربین داخل کابین با داده‌های سنسورهای حرکتی خودرو (مانند میزان انحراف فرمان، شتاب‌گیری یا ترمز ناگهانی) جهت کاهش هشدارهای اشتباه ( $False Positives$ ).
  ۴. پایش در شرایط نوری ضعیف و شب: آموزش و ارزیابی شبکه‌ها با استفاده از تصاویر مادون قرمز (Infrared/Thermal) جهت اطمینان از عملکرد پایدار سامانه در رانندگی شبانه.

### ۵.۸ سخن پایانی

نتایج به دست آمده در این پژوهش نشان داد که تلفیق رویکردهای عمیق یادگیری انتقالی با لایه‌های سفارشی‌سازی شده و استراتژی‌های هوشمند آموزش دو فاز، زیرساختی بسامان و پربازده برای خودکارسازی فرآیند تشخیص حواس‌پرتی راننده فراهم می‌آورد. این دستاوردها گامی موثر در راستای افزایش ایمنی جاده‌ای و کاهش تصادفات ناشی از خطای انسانی محسوب می‌شوند.