

سیستم هوشمند تشخیص حواس پرتی راننده

با رویکرد یادگیری انتقالی در شبکه‌های عصبی عمیق

اعضای تیم پروژه:

• حامد بهروزی مقدم (۴۰۲۱۵۶۳۳)

• امیرحسین شقاقی (۴۰۱۱۹۸۴۳)

مجموعه داده: State Farm (Kaggle)

دانشگاه: صنعتی خواجه نصیرالدین طوسی

استاد درس: دکتر نیکوفرد

نیمسال تحصیلی: ۱۴۰۴ - ۱۴۰۵

۱. بیان مسئله و اهمیت هوشمندسازی کابین

■ ضرورت مسئله: بر اساس گزارش WHO، حواس‌پرتی عامل بیش از ۲۰٪ از تصادفات جاده‌ای است. سامانه‌های بینایی ماشین داخل کابین می‌توانند با هشدار به موقع جان انسان‌ها را نجات دهند.

■ هدف سیستم: طبقه‌بندی خودکار تصاویر راننده به ۱۰ کلاس رفتاری مجزا:

c0: رانندگی عادی (Normal)	c5: تنظیم رادیو (Radio)
c1: پیامک - دست راست	c6: نوشیدن مایعات (Drinking)
c2: مکالمه تلفنی - دست راست	c7: دسترسی به صندلی عقب
c3: پیامک - دست چپ	c8: مرتب‌سازی مو و آرایش
c4: مکالمه تلفنی - دست چپ	c9: صحبت با سرنشین دیگر

۲. تحلیل داده‌ها (EDA): بررسی ابعاد تصاویر



تصویر ۱: توزع‌های جامع تحلیل اکتشافی (EDA) و توزیع کلاس‌ها

■ حجم مجموعه داده: شامل ۲۲,۴۲۴ تصویر رنگی آموزشی با وضوح بالا.

■ پراکندگی ابعاد: بررسی‌ها نشان داد تمامی تصاویر دارای رزولوشن ثابت 640 در 480 پیکسل (نسبت 4:3) هستند.

■ الزام شبکه‌های عمیق: برای تطابق با معماری‌های ImageNet (مثل ResNet و MobileNet)، نیاز است تمامی فریم‌ها در مرحله پیش‌پردازش به ساین استاندارد 224 در 224 تغییر اندازه داده شوند.


■ علاوه بر ابعاد، توزیع فراوانی کلاس‌ها هم در این تصویر مشخص است.

۳. تحلیل کیفیت بصری و ارزیابی نویز

■ سنجش وضوح (Sharpness): با محاسبه واریانس فیلتر لاپلاسین (آستانه کمتر از 30 به عنوان تار) انجام شد.

■ روشنایی و کنتراست: تحلیل توزیع پیکسلی نشان داد تغییرات نوری در کابین زیاد است (روز/سایه)، اما تصاویر کاملاً سیاه یا سوخته نداریم.

■ نتیجه بررسی سلامت: داده‌ها به شدت تمیز هستند؛ بدون عکس خراب (**Corrupted**) و فقط ۱ عکس بسیار تار شناسایی شد.



تصویر ۲: داشبورد تحلیل جامع کیفیت روشنایی، کنتراست و بلور شدگی

۴. بررسی بصری و چالش‌های درون‌کابین



تصویر ۳: تنوع حالات رانندگی، پوشش و نور در کلاس‌های ده‌گانه

■ زاویه دید: دوربین به صورت ثابت در سمت راست راننده و کمی بالاتر از داشبورد نصب شده است.

■ چالش‌های استخراج ویژگی:

- تنوع بالای فیزیک رانندگان (قد، لباس، عینک).
- انسداد (Occlusion): مخفی شدن دست در پشت فرمان.
- شرایط نوری متغیر به دلیل تابش آفتاب از پنجره‌ها.


۵. تحلیل شباهت بصری کلاس‌ها (Visual Similarity)

■ دلیل اهمیت: محیط پس‌زمینه (کابین) در همه عکس‌ها ثابت است، بنابراین مدل باید تفاوت‌های ریز رفتاری را یاد بگیرد.

■ کلاس‌های خلط‌آفرین (شباهت بالای ۸۵٪):

- پیامک با دست راست (c1) ↔ تلفن با دست راست (c2)
- پیامک با دست چپ (c3) ↔ تلفن با دست چپ (c4)

■ راهکار: مدل باید توجه ویژه‌ای به موقعیت دقیق دست‌ها نسبت به گوش و فرمان داشته باشد.



تصویر F: ماتریس شباهت کسینوسی مبتنی بر هیستوگرام RGB

۶. استراتژی حیاتی ضد-نشت (Anti-Leakage)

- معضل نشت داده: مجموعه داده شامل ۲۶ راننده (Subject) است. استفاده از تقسیم تصادفی (Random Split) باعث می‌شود شبکه به جای یادگیری «حواس‌پرتی»، چهره و لباس راننده را حفظ کند و دقت کاذب ۹۹٪ بدهد!
- راهکار GroupShuffleSplit: تفکیک داده‌ها بر اساس شناسه راننده انجام شد. هیچ راننده‌ای به طور مشترک در مجموعه‌های آموزش و اعتبارسنجی حضور ندارد.
- متوازن‌سازی هوشمند: جبران کمبود تصاویر در برخی کلاس‌ها تا سقف ۲۳۰۰ عکس به کمک افزونه‌سازی (Augmentation).




تصویر ۵: توزیع کلاس‌ها قبل و بعد از متوازن‌سازی هوشمند

۷. راستی‌آزمایی عدم تکرار (Duplicate Detection)


- الگوریتم MD5: برای بررسی کپی‌های دقیق پیکسلی استفاده شد و اطمینان کامل حاصل گردید که هیچ فایل کاملاً یکسانی بین مجموعه‌های Train و Test وجود ندارد.
- الگوریتم pHash (هش ادراکی): تصاویری که از نظر بصری بسیار شبیه به هم بودند (مانند فریم‌های متوالی و پشت سر هم یک ویدیو) با فاصله هامینگ بسیار کم شناسایی شدند.
- نتیجه‌گیری: خروجی این الگوریتم‌ها ثابت کرد که استراتژی جداسازی اصولی بر اساس شناسه راننده (GroupShuffleSplit)، کاملاً مانع از کالیراسیون غلط مدل روی فریم‌های همزاد شده است.

۸. استراتژی داده‌افزایی (Data Augmentation)

⚠ چالش چپ و راست: پارامتر **Horizontal Flip** حتماً باید غیرفعال (False) بماند. قرینه‌سازی افقی باعث تبدیل دست راست (کلاس c1) به دست چپ (کلاس c3) شده و لیبل داده‌ها را تخریب می‌کند!



تصویر ۸: پیش‌نمایش داده‌افزایی کلاس c0 (رانندگی عادی و تغییرات روشنایی)



تصویر ۷: پیش‌نمایش داده‌افزایی کلاس c8 (آرایش مو و صورت)


۹. معماری مدل اول: MobileNetV2 سفارشی

■ چرا MobileNet؟ استفاده از کانولوشن‌های عمقی-جدایی (Depthwise Separable) به جای کانولوشن استاندارد، حجم پارامترها را به شدت کاهش داده و مناسب پردازش بلادرنگ روی برد خودرو است.

■ تغییرات در Classifier Head:

1. لایه Global Average Pooling
2. لایه Dense(512) + Dropout(0.5)
3. لایه Dense(256) + Dropout(0.3)
4. لایه Softmax نهایی برای ۱۰ کلاس

■ منظم‌سازی (Regularization): استفاده از جریمه L2 (میزان $1e-4$) در لایه‌های متراکم.



تصویر ۹: بلوک‌دیگرام لایه‌های افزوده شده به هسته MobileNetV2

۱۰. پایپلاین و آماده‌سازی نهایی داده‌ها



«تصویر ۱۰: تایید صحت بچ خروجی از ژنراتور پس از پیش‌پردازش و نرمال‌سازی» MobileNetV2 (مرجع پایپلاین آموزشی)

■ مقیاس‌دهی (Rescaling):

تبدیل شدت پیکسل‌ها از بازه 0 تا 255 به بازه استاندارد 0 تا 1 در قالب Float32.

■ انکودینگ: نگاشت لیبل‌ها

به صورت بردارهای One-Hot برای محاسبه بهینه خطای آنتروپی متقاطع.


■ اندازه دسته (Batch Size):

تنظیم روی ۱۲۸ جهت استفاده حداکثری از توان موازی‌سازی پردازنده‌های گرافیکی (GPU).

جمع‌بندی بخش پیش‌پردازش (آماده برای دفاع)

چالش / موضوع	راهکار پیاده‌سازی شده در کد
نشت داده میان رانندگان	استفاده از GroupShuffleSplit برای جداسازی کامل ۲۶ راننده.
شباهت کلاس چپ و راست	لغو کامل قرینه‌سازی افقی (Horizontal_Flip = False).
نامتوازن بودن کلاس‌ها	داده‌افزایی هوشمند هدفمند (تارگت: ۲۳۰۰ عکس در هر کلاس).
محدودیت سخت‌افزار خودرو	استفاده از معماری سبک‌وزن MobileNetV2 .


نگاهی اجمالی به عملکرد کلی MobileNetV2



تصویر: داشبورد جامع متریک‌های آموزش، خطا و نرخ یادگیری MobileNetV2

- پیش‌نمایش نتایج: پیش از ورود به بررسی دقیق فازهای آموزش، در این داشبورد نمایی کلی از خروجی نهایی مدل را در طول هر ۲۳ اپیاک مشاهده می‌کنید.
- دقت نهایی: مدل موفق شده با وجود سبک بودن، به دقت بسیار مطلوب **۹۴.۴۲٪** روی داده‌های اعتبارسنجی دست یابد.
- پایداری آموزش: نمودارها نشان‌دهنده عدم وجود بیش‌برازش (Overfitting) مخرب و اثربخشی استراتژی تنظیم نرخ یادگیری (نمودار سبز رنگ) هستند.

۱۱. آموزش MobileNetV2 (فاز اول: استخراج ویژگی)



تصویر ۱۱: منحنی‌های یادگیری (Accuracy, Loss, Top-3) در فاز اول (۱۵ اپیاک)

■ استراتژی آموزش: در فاز اول (۱۵ اپیاک)،

پایه‌های مدل (Backbone) که روی ImageNet آموزش دیده بودند، کاملاً فریز (Frozen) شدند تا وزن‌هایشان تخریب نشود.

■ نرخ یادگیری (Learning Rate): شروع با $1e-3$ و استفاده از الگوریتم بهینه‌ساز Adam (0.001).

■ عملکرد: مدل با سرعت خوبی همگرا شد و به دقت اعتبارسنجی **۸۹.۷۶٪** و دقت Top-3 برابر با **۹۸.۰۴٪** رسید.


■ نتیجه: لایه‌های طبقه‌بند (Classifier Head) کاملاً با شکل کلی داده‌های حواس‌پرتی آشنا شدند.

۱۲. آموزش MobileNetV2 (فاز دوم: تنظیم دقیق / Fine-Tuning)

■ آزادسازی لایه‌ها: لایه‌های پایانی شبکه اصلی (از لایه ۱۰۰ به بعد) Unfreeze شدند تا ویژگی‌های اختصاصی کابین خودرو را یاد بگیرند.


■ کاهش شدید نرخ یادگیری: برای جلوگیری از پدیده فراموشی فاجعه‌بار (Catastrophic Forgetting)، نرخ یادگیری به $1e-5$ کاهش یافت.

■ جهش عملکرد: دقت اعتبارسنجی (Validation) به **۹۴.۴۲٪** ارتقا یافت و خطای اعتبارسنجی تا حد 0.28 پایین آمد.



تصویر ۱۲: منحنی‌های یادگیری فاز دوم (تنظیم دقیق - ۸ اپاک)

۱۳. تکامل کلی آموزش و زمان‌بندی نرخ یادگیری




تصویر ۱۳: تکامل متریک‌ها و رفتار نرخ یادگیری در طول ۲۳ اپیاک

■ نمای کلی (Complete Evolution): اتصال نمودارهای فاز ۱ و ۲ نشانگر تأثیر شگرف Fine-Tuning در اپیاک ۱۶ است (جهش نمودار).


■ کال‌بک‌ها (Callbacks):

- ReduceLROnPlateau: با گیر کردن مدل در فلات، نرخ یادگیری نصف شد (سقوط پله‌ای در نمودار سبز).
- EarlyStopping: برای جلوگیری از Overfitting.
- ModelCheckpoint: ذخیره خودکار بهترین وزن‌ها.

۱۴. ارزیابی نهایی MobileNetV2 (ماتریس درهم‌ریختگی)





تصویر ۱۵: ماتریس درهم‌ریختگی (Confusion Matrix) روی اعتبارسنجی



تصویر ۱۶: مقایسه جهش عملکرد از فاز ۱ (آبی) به فاز ۲ (صورتی)

۱۵. منحنی ROC و تست عملی MobileNetV2



تصاویر ۱۶ و ۱۷: منحنی ROC (بالا) و پیش‌بینی روی ۱۰ نمونه تصادفی Test (پایین)


- منحنی ROC (One-vs-Rest): سطح زیر نمودار (Macro AUC) برای مدل MobileNetV2 بسیار نزدیک به 1.00 است که نشان‌دهنده قدرت بالای تمایز بین ۱۰ کلاس است.
- پیش‌بینی روی داده‌های Test: مدل روی تصاویری که هرگز در طول آموزش ندیده بود، با سطح اطمینان (Confidence) بالای ۹۰٪ به درستی کلاس‌ها را پیش‌بینی کرد.

۱۶. ارتقای رویکرد: معرفی معماری ResNet50

■ چرا شبکه ResNet50؟ برای دستیابی به دقت‌های بالاتر، از شبکه بسیار عمیق‌تر ResNet50 استفاده کردیم. این شبکه با استفاده از اتصالات میان‌بر (Residual Connections) مشکل محوشدگی گرادیان (Vanishing Gradient) را حل می‌کند.


■ تغییر پیش‌پردازش: برخلاف MobileNet، ورودی شبکه ResNet50 نیاز به تابع `preprocess\_input` مخصوص خود دارد (پیکسل‌ها ضرب در 255.0 می‌شوند).

■ تنظیمات یکسان: اندازه بچ (128)، توابع منظم‌سازی L2 و دراپ‌اوت (Dropout) دقیقاً مشابه مدل قبلی تنظیم شدند تا مقایسه عادلانه باشد.



تصویر ۱۹: دیاگرام معماری شبکه ResNet50 با لایه‌های Classification سفارشی

۱۷. آموزش ResNet50 (فاز اول: استخراج ویژگی)



تصویر ۳۰: متحنی‌های یادگیری فاز اول مدل ResNet50 (سرعت بالای همگرایی)

■ قدرت شبکه‌های بسیار عمیق: تنها در همان فاز اول (فریز بودن پایه‌ها) طی ۱۵ اپیاک، مدل با سرعت خیره‌کننده‌ای همگرا شد.

■ شکستن مرزها: دقت اعتبارسنجی (Validation Accuracy) در همان فاز اول به **۹۹.۵۲٪** رسید!


■ دقت Top-3: عملاً به ۱۰۰٪ (۹۹.۹۸٪) میل کرد که نشان از ظرفیت بسیار بالای ResNet50 برای درک الگوهای پیچیده و بافت کابین خودرو دارد.

۱۸. آموزش ResNet50 (فاز دوم: تنظیم دقیق / Fine-Tuning)

■ استراتژی آزادسازی: لایه‌های شبکه از بلوک ۱۰۰ به بعد آزاد شدند تا شبکه بتواند الگوهای پیچیده‌تر (مانند تفاوت گوشه و دست خالی) را کاملاً درونی‌سازی کند.

■ دقت خیره‌کننده: در پایان این فاز، دقت اعتبارسنجی (Validation Accuracy) به عدد بی‌نظیر **۹۹.۵۸٪** رسید!

■ دقت Top-3: برابر با ۹۹.۹۸٪ ثبت شد که نشان می‌دهد مدل تقریباً در ۱۰۰٪ مواقع، کلاس صحیح را در بین ۳ حدس اول خود قرار داده است.





تصویر آ: منحنی‌های یادگیری فاز دوم (تنظیم دقیق - ۸ اپاک)

تکمیل تحلیل MobileNetV2 و ورود به قلمرو ResNet50

تا به اینجا دیدیم که مدل سبک‌وزن ما (MobileNetV2) دقت بسیار خوب $\sim 94.5\%$ را ثبت کرد. همچنین مدل سنگین‌وزن (ResNet50) در همان قدم‌های اول نوید دقت‌های بالای 99% را داد.

در بخش پایانی، به سراغ نتایج نهایی ResNet50 و مقایسه هیجان‌انگیز این دو شبکه می‌رویم...

۱۹. تکامل آموزش و عملکرد کلی (ResNet50)





تصاویر ۲۳ و ۲۴: تکامل ۲۳ اپیاک آموزش (بالا) و نمودار میله‌ای مقایسه بهترین عملکرد فازها (پایین)

■ پایداری آموزش: برخلاف شبکه‌های کم‌عمق، نمودار خطای اعتبارسنجی (Validation Loss) در ResNet50 هیچ نوسان شدیدی ندارد و روی عدد 0.16 کاملاً پایدار شده است.

■ مقایسه دو فاز: جهش دقت از فاز اول به دوم محسوس است، اما به دلیل قدرت بالای پایه‌های ResNet، حتی فاز اول نیز دقت بالای ۹۸٪ را ثبت کرده بود.

۲۰. ارزیابی نهایی و ماتریس درهم‌ریختگی (ResNet50)



تصاویر TF و T0: ماتریس درهم‌ریختگی (بالا) و منحنی‌های ROC چندکلاسه (پایین)

- قطر اصلی ماتریس: تمرکز مطلق روی قطر اصلی نشان می‌دهد که خطاهای طبقه‌بندی (Misclassifications) به شکل چشمگیری در این مدل کاهش یافته‌اند.
- منحنی ROC و AUC: در تمامی ۱۰ کلاس، سطح زیر نمودار (AUC) تقریباً برابر با 1.000 است که نشان از قابلیت تفکیک‌پذیری کامل مدل دارد.

۲۱. تست عملی و استنتاج مدل (ResNet50)

- پیش‌بینی تصاویر جدید: مدل روی مجموعه تصادفی از تصاویر Test (که لیبل آن‌ها مخفی بوده) ارزیابی شد.


- اطمینان شبکه (Confidence): برخلاف مدل‌های ضعیف که با درصد اطمینان شکننده پیش‌بینی می‌کنند، ResNet50 در اکثریت قریب به اتفاق موارد با اطمینان **بالای ۹۹٪** رفتار راننده را طبقه‌بندی کرده است.

- پیش‌پردازش متفاوت: در زمان استنتاج، ورودی‌ها دقیقاً مشابه پایلاین آموزش با تابع مخصوص resnet_preprocess مقیاس‌دهی شده‌اند.



تصویر ۲۶: پیش‌بینی قدرتمند مدل ResNet50 با درصد اطمینان بالا روی ۱۰ نمونه تست

۲۲. مقایسه جامع: MobileNetV2 در برابر ResNet50



تصویر ۲۸: رقابت رودررو: دقت ResNet (بنفش) در برابر MobileNet (قرمز)

■ سرعت همگرایی: همان‌طور که در نمودار پیداست، ResNet50 از همون ایپاک‌های ابتدایی با اختلاف زیادی بالاتر از MobileNet قرار گرفته است.

■ دقت نهایی:

• ResNet50: ~۹۹.۵%

• MobileNetV2: ~۹۴.۴%

■ نتیجه تحلیلی: عمق شبکه و

استفاده از بلوک‌های پسماند

(Residual) در ResNet50 باعث

استخراج ویژگی‌های بسیار غنی‌تری

از بافت و پیکسل‌های تصویر شده

است.

۲۳. ارزیابی خروجی‌های همزمان و تحلیل معماری

■ مصالحه دقت و سرعت (Trade-off):

۱. **MobileNetV2**: با پارامترهای بسیار کمتر، فوق‌العاده سریع است و برای تعبیه مستقیم روی پردازنده‌های ضعیف داخل خودرو ایده‌آل است.
۲. **ResNet50**: دقت خیره‌کننده‌ای دارد اما نیازمند توان پردازشی بیشتری است (مناسب برای پردازش ابری یا Edge قدرتمند).



تصویر ۲۷: پیش‌بینی مقایسه‌ای همزمان روی داده پکسان (ResNet در برابر MobileNet)

با سپاس از توجه شما

پایان ارائه

آماده پاسخگویی به پرسش‌های شما هستیم.

